中文教学精读 • NEURIPS 2025

因果区分概念
从推导到实跑

Causal Differentiating Concepts: Interpreting LM Behavior via Causal Representation Learning

Navita Goyal、Hal Daumé III、Alexandre Drouin、Dhanya Sridhar

NeurIPS 2025正式版，29页；正文、附录A–C、公式(1)–(5)、全部原图与表。

含基础补课、逐式推导、证明核查、中英词典与63次独立实跑。

未取得作者代码；新增计算不是官方代码复现，大型LLM/SAE原实验未执行。

作者报告、条件化结论、教学诊断与本地实跑分别标记；非作者正式勘误。

先修｜从零补课：读懂这篇论文需要的数学

> **这是教学补充，不是论文新增结论。** 本章不用你预先记得线性代数、概率或优化。先抓住“文本→激活→概念→行为”这条主线，遇到虚线术语可以点开词典。

1. 先分清五个东西

符号	是什么	例子
x	输入文本	一段职业简介及提问
$g(x)$	模型内部可提取的激活	768维向量
z	我们希望发现的真实中介概念	性别编码、职业收入等级
$\hat{z} = \tau(g(x))$	算法学出的低维特征	两个实数，但起初不知道各自含义
c	想解释的粗粒度行为类别	高收入判断、低收入判断等

“概念没标签”不等于“完全没有任何标签”：训练仍知道每条输入属于哪个行为组c。



教学图：训练可见文本、激活和行为；真实概念仅在可控实验中用来评价。箭头表示建模流程，不宣称已恢复现实因果图。

2. 向量只是有顺序的一串数

$z = (2, 3)$是一个二维向量。第一个分量可能表示职业等级，第二个表示另一个属性。坐标的单位和顺序是约定，不是自然定律。

从$(2, 3)$变成$(2, 7)$，变化量是$(0, 4)$。只有一处非零叫**单稀疏变化**。它不要求原向量本身稀疏。

标准基向量$e_1 = (1, 0)$、$e_2 = (0, 1)$是两条坐标轴的单位箭头，所以$(0, 4) = 4e_2$。

3. 矩阵是在做混合

$$A = \begin{pmatrix} 2 & 1 \\ -1 & 3 \end{pmatrix}, \quad Az = \begin{pmatrix} 2z_1 + z_2 \\ -z_1 + 3z_2 \end{pmatrix}.$$

代入$z = (1, 2)$，得到$Az = (4, 5)$。两个新坐标都混合了旧概念：能保留信息，却不再逐轴对应语义。

矩阵乘e_1会抽出第一列：$Ae_1 = (2, -1)$。这正是公式(5)为什么能把“单坐标变化”转换成“矩阵某列只有一个非零数”。

4. 满秩、可逆与覆盖

秩表示独立方向有多少。$(1, 0)$与$(2, 0)$虽然有两条箭头，却只张成一条线；$(1, 0)$与$(0, 1)$才能覆盖整个平面。

$$\operatorname{rank} \begin{pmatrix} 1 & 0 \\ 2 & 0 \end{pmatrix} = 1, \qquad \operatorname{rank} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = 2.$$

矩阵“行很多”不保证满秩。四个行为类别的权重都平行，仍然只提供一个方向的信息。这是核查定理1时最重要的基础。

5. 仿射、旋转、尺度与置换

仿射变换是$\hat{z} = Az + b$，包括混合A和统一平移b。

- 置换：把第一、第二坐标对调。
- 尺度：把某个坐标乘2或乘-1。
- 旋转：两个坐标互相混合，但不一定丢信息。

“识别到置换和尺度”表示算法找到了正确的轴，但不能凭数据确定轴的顺序、方向和单位。若未中心化，平移也不能由差分损失识别。

6. 概率与条件概率

$p(c=1 \mid z)$读作“给定概念z时，行为为1的概率”。固定z后，各行为类别概率之和是1。

同一组概念若对应随机行为，就不能再假装c一定是z的确定函数。论文在高层模型$\mathcal{M}$与条件概率间切换，严格阅读时必须注明采用哪一种解释。

7. 条件独立不是所有变量相互独立

$c \perp x \mid z$表示：知道z后，x不再提供额外的行为预测信息。

例如如果模拟标签只由性别与收入等级生成，知道这两个因素后，简介里的标点不再影响模拟标签。它没有说性别与职业彼此独立，也没有证明现实收入只受这两者影响。

8. 指数、对数和Softmax

指数$\exp(t)=e^t$把实数变成正数。对数log是其反操作：$\log(e^t)=t$。

$$p(c \mid z)=\frac{\exp(w_c^\top z)}{\sum_j \exp(w_j^\top z)}.$$

两类分数$(0, \log 3)$对应概率$(1/4, 3/4)$。同时给所有分数加5，概率不变，因为分子分母都多乘e^5。

不要把分母看作输入无关常数：输入变了，所有分数通常都变。

9. 对数几率为什么能消去分母

用类别0作参考：

$$\log \frac{p(c \mid z)}{p(0 \mid z)}=(w_c-w_0)^\top z.$$

这是两个概率相除后，**同一个输入的同一个分母**精确抵消。它不同于对单个$\log p(c \mid z)$随意丢掉归一化项。

10. 交叉熵是什么

真实标签为c时，模型损失是$-\log \hat{p}_c$。给正确类别概率越高，损失越低：

$$-\log 0.9 \approx 0.10536, \qquad -\log 0.1 \approx 2.30259.$$

如果真实类别比例是$(0.25, 0.75)$，预测同样比例时总体平均损失约0.562335；始终预测$(0.5, 0.5)$时是$\log 2 \approx 0.693147$。

总体交叉熵的最低点是“正确预测概率”，不保证神经网络在有限数据和有限轮次就到达该点。

11. 范数与平方误差

向量$v = (3, 4)$的欧氏长度是$\|v\| = 5$，平方长度$\|v\|^2 = 25$。两者不是一个损失。

本篇正式PDF公式(4)中的2是**上标平方**。我们计算的是平方残差；不能把原文偷偷改写成未平方的欧氏长度，然后用同一数值比较。

12. 最小值、期望与求和

- $\min$：在候选中找最小值。
- $\mathbb{E}$：按概率加权平均。
- $\sum$：把多项相加。

候选损失是4、1、9，最小值为1，平均为$14/3$。一般$\mathbb{E}[\min L]$不等于$\min \mathbb{E}[L]$；论文的简写与附录采样实现需要区别说明。

候选越多，取得小最小值的机会通常越大。所以比较方法时必须保持候选预算一致。

13. 换位干预与自然配对

已有$z_A = (0, 0)$、$z_B = (1, 2)$。只替换第一坐标，可构造$(1, 0)$。

这是一个**反事实状态**。观察数据只有前两点时，并没有证据说自然样本中存在$(1, 0)$。从高层干预转成可供搜索的真实文本，需要额外的可实现性或支撑条件。

14. 必要、充分与量词

“必要”是没有它不行；“充分”是有它就够。两者合起来也必须看“对所有”还是“存在一些”。

本文必要条件是强的全称条件，充分条件仅要求存在某对样本干预成功。不能把“存在一例”读成“任意样本都成功”。

15. 导数、梯度与训练

若$L(a)=(a-3)^2$，导数$L'(a)=2(a-3)$。在$a=1$时导数为-4，取步长0.1更新：$a \leftarrow 1-0.1(-4)=1.4$，更接近3。

神经网络把a换成很多参数，梯度是每个参数的导数。自动求导可以算梯度；有限差分可以检查实现，但不能证明优化总能找到全局最优。

16. VAE与瓶颈

VAE学习压缩与重构，并加一个分布约束；本文先借它得到合成数据的低层特征$g(x)$。之后再训练τ得到用于解释的瓶颈。

仅靠重构或预测，许多旋转后的瓶颈都同样好。对比约束的目的，就是尝试从这些等价坐标中选出概念轴。

17. D、C、I和MCC分别问什么

指标	问题	不能说明什么
D	一个学习轴是否只负责一个真实因素?	不能独立证明信息没丢
C	一个真实因素是否集中在一个学习轴?	不等于覆盖全部现实因素
I	全部学习特征能否预测真实因素?	高I不等于坐标已经对齐
MCC	最佳一一配对后线性相关多强?	不能检测所有非线性等价关系

矩阵$R=\begin{pmatrix}0.8 & 0.2\\ 0.2 & 0.8\end{pmatrix}$给出$D=C=1-H_2(0.8)\approx 0.278072$。不要把0.8直接当作解缠分数。

18. 数据划分与公平比较

训练集用于更新参数，验证集用于选择轮次，测试集只在最后评估。标准化均值和标准差也必须只用训练集估计。

这次合成实验每个数据集20000条，按70:15:15得到14000、3000、3000条。所有方法使用同一数据、划分和轮次，不按测试指标挑模型。

19. 均值、标准差和显著性

三次结果是$0.5, 0.6, 0.7$，均值为0.6，样本标准差为0.1。写0.6 ± 0.1时必须说明这是SD，不是95%置信区间。

重新训练3次与把同一模型的测试集切成3份，描述的波动不一样。少量重复的统计检验很不稳定，本材料保留逐种子结果，不用一颗“显著星号”替代它们。

20. 五个自测

1. 两个学习坐标混合了职业和性别，但可以无误预测行为，能否认定解缠?
2. 四个类别的权重都是$(1, 1)$的倍数，是否一定能识别二维概念?
3. 反事实$(1, 0)$可生成，是否说明真实数据已有这个输入?
4. 表征整体乘0.1，预测头除以0.1，平方对比损失如何变化?
5. DCI-I在本地连续实验采用测试R^2，能与另一个未披露定义的1.0直接作严格数值比较吗?

▼ 查看答案

1. 不能，行为信息充分不等于逐轴语义对齐。
2. 不一定，权重差最多秩1。
3. 不能，需要可实现性/闭包条件。
4. 预测logits不变；扰动同样缩放后，平方残差变为原来的0.01。
5. 不能，先统一评价器、数据与指标定义。

继续：整篇路线图。所有手算数值与基础例子由验证脚本重新计算；有限检验不替代一般证明。

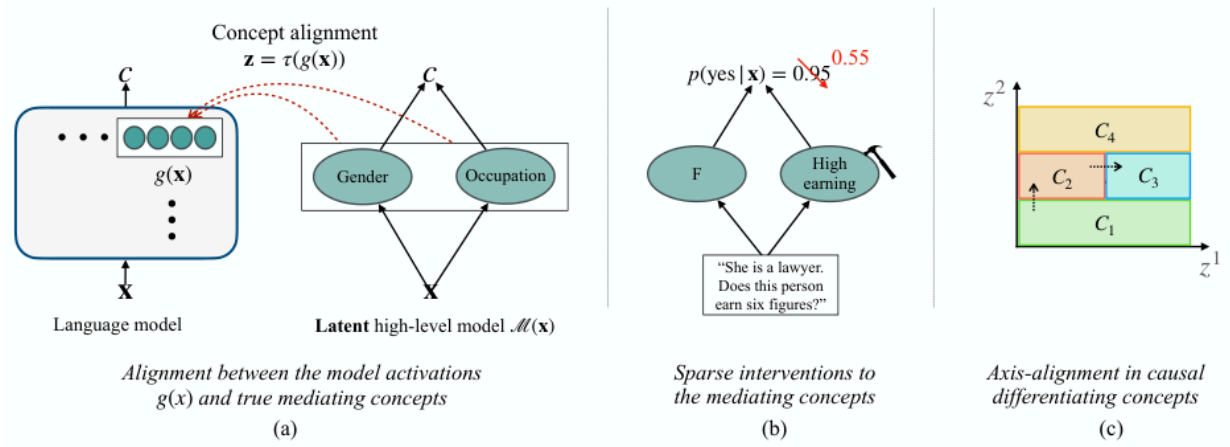
00 | 先看全貌：这篇论文究竟想解决什么

一句话

语言模型内部的激活把多个概念混在一起。作者先按**行为**分组，再寻找组间近似只改变一个潜在坐标的样本，试图学习能够逐轴解释行为的低维表示。

原论文： Causal Differentiating Concepts: Interpreting LM Behavior via Causal Representation Learning，Navita Goyal、Hal Daumé III、Alexandre Drouin、Dhanya Sridhar，NeurIPS 2025正式版，共29页。

下载： 完整中文PDF · 基础补课PDF · 计算证据包 · 完整离线学习包 · 交互实验室。公开主页左侧目录可直达各章，手机点左上角三展开。



原图1节选（PDF第2页，版权归原作者）：左边是激活到概念的对齐，中间是高层换位干预，右边是行为组间的稀疏变化。下面的推导会说明哪些联系还需要额外条件。

论文、教学、计算，分三个层次读

标记	含义
原文陈述/原文报告	论文写出的定理、方法、分数；不是本次重新运行所得
补充推导/条件化结论	把省略步骤展开；补充条件会明确列出
本地实跑	脚本实际执行，保留预测、配置、种子和日志
教学诊断	用精确代数或有限例子检查论证环节；不冒充全定理反例
未执行	本机无法做或缺少必要代码/模型资源的原规模实验

用户要求“数据证明经过计算”，这里落实为：**本次新增的数值可由原始输出重算，代数例子可精确核验；不能重算的作者结果明确标记。** 数学普遍命题仍依赖证明，不能用电脑测试几个点替代。

三条主线

1. **理论线：** 行为可预测 → 仿射等价类 → 单坐标变化 → 尺度/置换等价类。
2. **算法线：** 激活 → 瓶颈 → 线性行为头；加组间单稀疏平移约束。
3. **证据线：** 合成数据有真实因素 → 半合成文本有模拟因素 → 拒答案例只有可解释性线索。

第三条越往后越贴近真实模型，但能直接验证的因果结论越少。

本次交付的实验范围

- 合成：6种设置（二维/三维，各3种混合）、3个固定种子、3个方法，共54次瓶颈训练；每个数据集20000条。
- 真实文本半合成：2400条公开简介、冻结DistilBERT激活、3种方法×3种子，共9次训练。
- 代数/数值诊断：秩、log-odds、可实现性、稀疏列、尺度、旋转目标、梯度和指标。
- 未执行：7B/8B原规模训练、真实拒答与64个LlamaScope SAE的原实验。

不是官方代码复现。 论文称补充材料提供代码，但本次未取得该附件；未找到公开仓库不等于作者从未发布。所有自行选定的实现约定都会列出。

推荐阅读顺序

基础不熟：先修 → 01、02 → 03、04 → 07、09 → 再读05、06、11。

做研究：00 → 02–06 → 08、09 → 11–13；务必把“条件化的稀疏列引理”和“原文未知配对目标的全局保证”分开。

本手册	对应原文
01–02	正文1–3节：动机、设定、定义与假设
03–04	公式(3)(4)、附录B实现
05–06	定理1、2及附录A完整证明路线

本手册	对应原文
07	DCI、MCC及统计评价
08	正文4–7节，表1–3、图2–3、7–8
09	本次新增的全部实跑结果与计算图
10	附录C：维度、层与2-sparse扩展
11	理论与复现核对，不是作者正式勘误
12–13	相关研究、上一篇联系、学习计划与复现实操
词典	按需查询的中英术语

本网站可离线阅读与打印，阅读进度只保存在当前浏览器，不在设备间同步。原论文全文链接到正式来源；本站不把未核实的授权当作CC BY 4.0。

01 | 从收入例子建立模型：相关、预测和因果别混在一起

1.1 作者的动机，不是现实收入规律

原文设想：输入候选人简介，问模型是否年薪达到六位数。模型对高收入职业更倾向回答“是”，低收入职业更倾向“否”，中等收入职业中还可能表现出性别差异。

这是**解释模型行为的例子**，不是证明现实薪资由性别和职业充分决定，更不是认可这种预测规则。

半合成实验进一步把规则人工写进标签。恢复这种标签规则，证明的是算法在受控设置的能力，不等于发现了现实世界的完整薪资因果机制。

1.2 文本回答与行为类别不同

模型输出可以是长文本y，但论文先把它压成m个类别c。例如许多不同拒答句都可能归为同一行为类别。

行为类别的生成可以由专家指定，也可以由输出概率聚类。不同聚类方法、阈值或模型版本会改变c，从而改变“最能解释这些行为的概念”。

论文公式(3)沿用了y作分类索引；本手册统一用c写损失，避免把整段文本当成softmax类别索引。

1.3 高层模型到底做了什么

论文希望存在高层概念z，使

$$c \perp x \mid z.$$

含义是：知道z后，不需要完整输入x也能解释行为分布。算法观察$g(x)$，学习

$$\hat{z} = \tau(g(x)), \qquad \hat{p}(c \mid x) = h(\hat{z})_c.$$

足够预测并不等于坐标正确。 如果$\hat{z} = Az$且A可逆，分类器总可以吸收逆变换，所以预测能力可能完全不变。

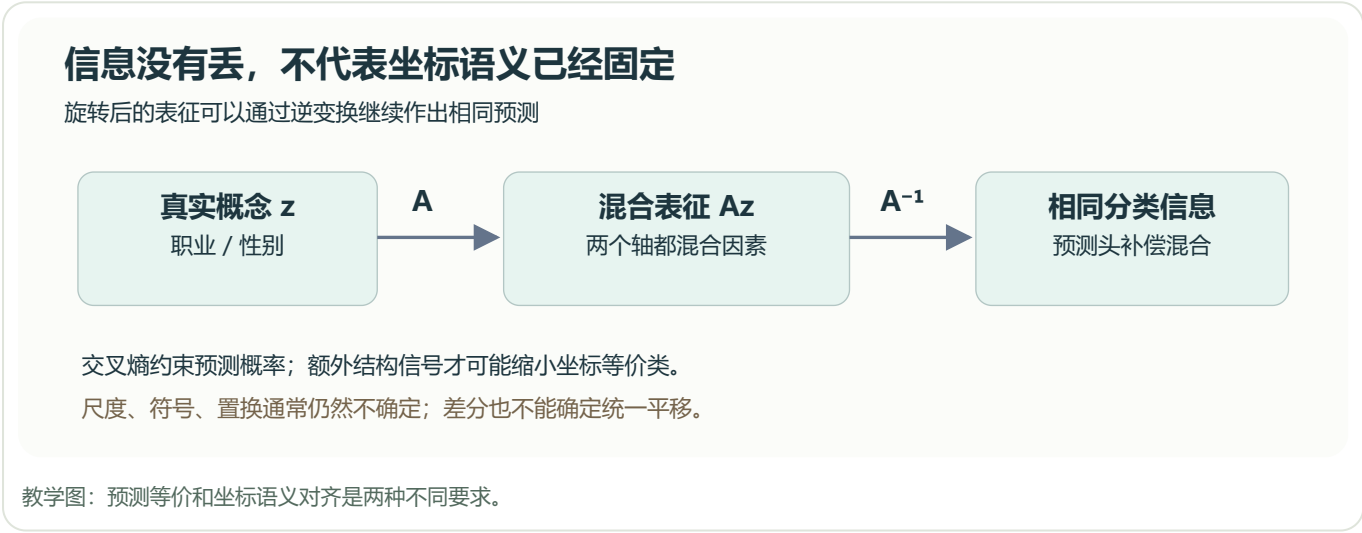
1.4 一个完整可算的例子

取$z=(1,2)$，$A=\begin{pmatrix}2 & 1\\ -1 & 3\end{pmatrix}$，于是$\hat{z}=(4,5)$。真实分类权重若为$w=(1,0)$，则真实分数$w^\top z=1$。

选择$\hat{w}=A^{-\top}w=(3/7,-1/7)$，学习分数为

$$\hat{w}^\top\hat{z}=\tfrac{3}{7}\times 4-\tfrac{1}{7}\times 5=1.$$

行为预测一致，但学习坐标$(4,5)$各自都混合了两个真实因素。公式(4)的任务不是再提高这个分数，而是尝试固定坐标含义。



教学图：预测等价和坐标语义对齐是两种不同要求。

1.5 “无监督”的准确说法

信息	训练时是否使用
输入x与模型激活$g(x)$	使用
行为标签c	使用
每条样本的真实概念z	核心训练目标不直接使用
已知纯反事实配对	不要求预先提供
完整高层因果模型	不要求预先提供
验证真实因素DCI	作者半合成调参使用；本次固定参数不使用

因此更准确地说，是**无需概念标签的行为条件概念发现**。不能宣传成完全没有监督信息。

1.6 比“神经元最大激活”多做了什么

单个激活维度可能同时编码语言、主题、语气、职业等特征。直接找某行为组激活最大的神经元，未必能找到人能理解的中介因素。

本文把解释映射τ作为学习对象，并用行为目标选择解释粒度。相比寻找模型里“所有概念”，这是更局部、更有针对性的目标，也意味着换一个行为任务可能得到不同概念。

1.7 本章检查点

若解释空间里两组样本分得很开，可以说表示含有区分组别的信息；若想进一步说“横轴就是伤害性，纵轴就是主题”，还需要标签、干预、稳定性或其他独立证据。二维可视化本身不是因果鉴定。

02｜定义、量词与两个关键假设

2.1 假设1：行为概率对概念是logit线性的

原文设

$$p(C=c \mid z)=\frac{\exp(w_c^\top z)}{\sum_{j=1}^{m}\exp(w_j^\top z)}.$$

线性的是**未归一化分数**$w_c^\top z$，不是概率本身，也不是所有激活到文本的映射。

最后一层激活线性影响下一个token的logits，可以作为动机；但“整段回答被粗化后的行为概率”不自动保留同样的logit线性结构。聚合多个token/输出类别通常需要求和、生成和聚类，这是额外建模假设。

2.2 定义1：换位干预

行为组为$C_k=\{x:c(x)=k\}$。取$x_k\in C_k$、$x_l\in C_l$，相关高层概念为z_k,z_l。

选择坐标集合$S\subseteq\{1,\dots,d\}$，把z_k的这些坐标换成z_l的相应坐标，其他坐标保持不动，然后在高层模型$\mathcal{M}$中计算行为。

例如$z_k=(0,1,5)$、$z_l=(1,2,9)$，若$S=\{2\}$，干预后的状态是$(0,2,5)$。这是坐标替换，不是两个样本整体对换。

2.3 定义2的必要条件：原文(1)

$$\mathcal{M}_{z_k^{S'}\leftarrow z_l^{S'}}(x_k)\neq c_l,\qquad \overline{S'}\cap S\neq\varnothing. \tag{1}$$

这里的横线表示相对全部概念坐标取补集。条件说：只要漏掉S里的任一必要坐标，就不能从k到达l，即使同时替换了其他坐标。

量词： 对任意相关x_k,x_l及满足条件的S'。这比“找到一次没换职业就失败”强得多。

2.4 充分条件：原文(2)

$$\mathcal{M}_{z_k^S \leftarrow z_l^S}(x_k) = c_l. \tag{2}$$

量词： 存在某对x_k, x_l，只替换S就能成功。它不要求每一对都成功。

把(1)(2)合起来，作者把z^S称为两个指定行为组的**因果区分概念。**若$S = \{r\}$，则是1-sparse CDC。

2.5 假设2：每个因素至少有一次单独起作用的机会

原文要求：每个真实坐标z_r，都至少是某一对行为组的1-sparse CDC。

不是：所有组对都只需要改变一个概念。也不是：任意两个样本都只相差一个坐标。

在收入例子中，中收入女性组与中收入男性组可由性别区分；低收入与高收入组可能由职业等级区分。不同坐标可以依靠不同组对被识别。

2.6 推论1：从干预转成样本差分

原文声称上述条件推出：对相应组对，存在观测样本使

$$z_l = z_k + \delta_{kl}, \qquad \delta_{kl} = ae_r, \quad a \neq 0.$$

这一步是算法能够“搜索样本对”而不直接做概念干预的桥梁，但需要认真核查：**只替换某坐标能改变行为，不意味着两个原始样本的其他坐标相同。**

教学反例：观测仅有$A:(0,0)$、$B:(0,1)$、$C:(1,2)$。高层规则为第一坐标是1就输出C，否则第二坐标是1输出B，其余输出A。

- A到C只替换第一坐标，得到$(1,0)$，行为变为C。
- 不替换第一坐标，无法从A到C。
- 但观测A和C相差两个坐标，观测集中没有$(1,0)$。

这个计算说明“反事实到观测配对”的逻辑还需要**可实现性或干预闭包。**它针对推论的这一环节，不是声称满足了全论文所有随机假设并反驳整个定理。



教学图：抽象干预、可实现输入与已观测样本是三个不同层次。

2.7 共享平移比“有纯配对”还强

若不同锚点需要不同幅度$a_i e_r$才能到目标组，存在单稀疏配对也不等于一个固定δ_{kl}适合所有锚点。

正文公式(4)写全组内最小配对；附录B则对一个锚点采5个候选。这两种目标对“平移共享”的要求不同，不能在实现时悄悄当成同一回事。

2.8 确定行为与随机行为的边界

正文既写$c = \mathcal{M}(x)$，又写严格正概率的softmax。若$\mathcal{M}$是确定性分组规则，可以直接谈干预后类别；若c是真实抽样结果，则要说明干预改变的是概率分布、最可能类别还是抽样值。

本次合成与半合成用**确定的分区标签**，便于复算；它们不是对严格随机softmax假设1的逐项复现。因此实验成功或失败都不能单独证明或否定原理论的全部条件。

03 | 逐式拆解目标：为什么预测还不够

3.1 原文(3)：用行为约束瓶颈

$$\min_{\tau,h} \mathbb{E}_{p(x,y)}[-\log h(\tau(g(x)))_y]. \tag{3}$$

为消除符号冲突，我们写成$\mathbb{E}_{x,c}[-\log \hat{p}(c \mid x)]$。$g$提供低层激活，$\tau$产生$d$维瓶颈，$h$是线性logits加softmax。

固定输入，若真实概率为p，预测为q，有

$$-\sum_c p_c \log q_c = -\sum_c p_c \log p_c + \sum_c p_c \log \frac{p_c}{q_c} = H(p) + D_{\mathrm{KL}}(p\|q).$$

由KL非负，能精确表示真实概率时总体最优解满足$q = p$。这需要**模型可实现、总体优化到最优**；有限训练损失下降不是同一命题。

3.2 交叉熵不固定坐标

若$\hat{z} = Az + b$且A可逆，预测头可用逆变换补偿。分类logits可以完全一致，所以交叉熵没有理由区分“职业、性别坐标”与其旋转混合。

瓶颈可以压缩无关信息，但没有一般结论说“维度低所以每轴有语义”。这需要后续条件。

3.3 原文(4)：组间共享单坐标平移

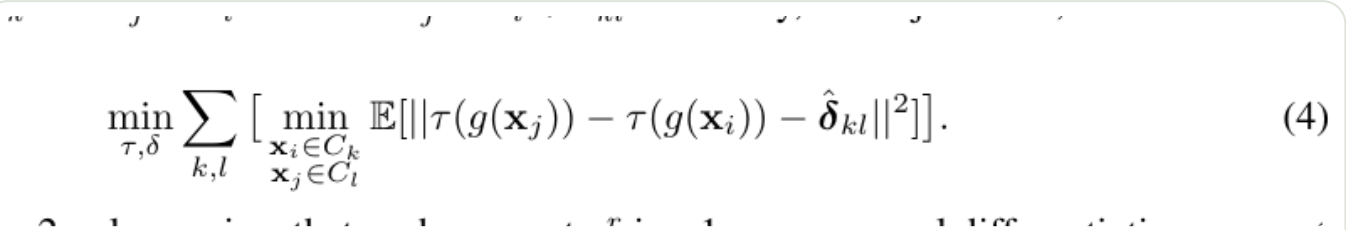
保留原式结构：

$$\min_{\tau,\delta} \sum_{k,l} \left[\min_{x_i \in C_k,\, x_j \in C_l} \mathbb{E}\left[\|\tau(g(x_j)) - \tau(g(x_i)) - \hat{\delta}_{kl}\|^2 \right] \right]. \tag{4}$$

其中$\hat{\delta}_{kl}$必须单稀疏；附带文字要求

$$\dim \operatorname{span}\{\hat{\delta}_{kl}\} = d.$$

原文“span等于d”应理解为张成空间的**维数**等于d。跨度是一个空间，不能直接与整数相等。



$$\min_{\tau,\delta} \sum_{k,l} \Big[\min_{\substack{\mathbf{x}_i \in C_k \\ \mathbf{x}_j \in C_l}} \mathbb{E}[||\tau(g(\mathbf{x}_j)) - \tau(g(\mathbf{x}_i)) - \hat{\boldsymbol{\delta}}_{kl}||^2] \Big]. \tag{4}$$

PDF第4页公式(4)节选：范数后的2是上标平方。原文未完全展开期望的随机对象和离散约束求解器，本次实现约定见第04章。

3.4 固定一个候选对，如何算残差

若$\hat{z}_i = (1, 2)$、$\hat{z}_j = (4, 6)$，差是$v = (3, 4)$。

选择轴1、扰动$\delta = ae_1$，平方误差为

$$\|v - ae_1\|^2 = (3 - a)^2 + 16.$$

最优$a = 3$，误差16。选择轴2时最优$a = 4$，误差9。所以固定这一个样本对、允许任意幅度时，最佳单轴近似选轴2。

一般地，对固定v与轴r，$a^* = v_r$，最小残差为$\|v\|^2 - v_r^2$。

但正文扰动是组对共享的。 若不同候选需要不同a，不能对每条配对都重新自由选幅度，再宣称等于原来的共享扰动目标。

3.5 附录B如何近似搜索

原文对$x_k \in C_k$从C_l采5个候选，取最小残差。给定δ时，候选损失$4, 1, 9, 6, 2$返回1。

这里有三种不同形式：

1. 全部样本中挑**一个最佳对**；
2. 每个锚点从候选中挑最佳，再对锚点平均；
3. 先对随机性取期望，再优化配对。

它们的统计性质不同。原文正文与附录存在简写，本次选择第2种，并明确记录锚点数、候选数与随机种子。

3.6 为什么需要覆盖

如果全部组对都沿同一轴找低误差，另一个坐标可能没有被识别。单稀疏不自动意味着每个因素都被覆盖。

若扰动矩阵为

$$D = \begin{pmatrix} 1 & 0 \\ 2 & 0 \\ -1 & 0 \end{pmatrix},$$

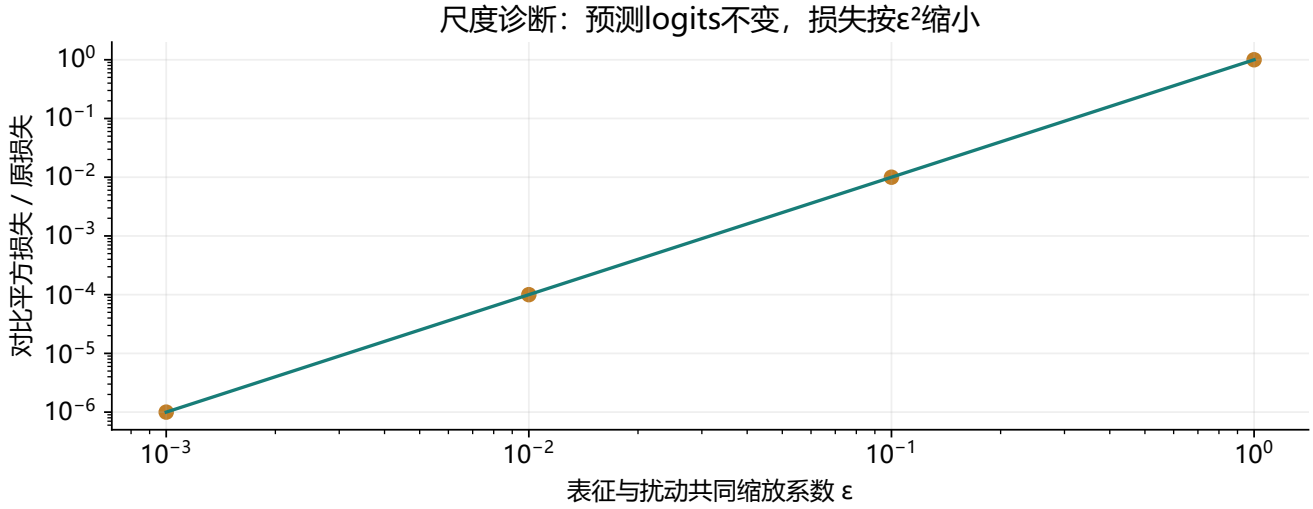
三条扰动仍秩1。需要非零扰动共同张成d维；仅给不同轴分配标签、但幅度为0，也不算覆盖。

3.7 尺度退化必须单独处理

令$\hat{z}' = \epsilon\hat{z}$、$\hat{\delta}' = \epsilon\hat{\delta}$，预测头权重除以$\epsilon$，则预测不变，而

$$L'_{\text{contrast}} = \epsilon^2 L_{\text{contrast}}.$$

任何$\epsilon > 0$都不改变扰动矩阵的秩，却能让平方残差任意小。除非有尺度归一化、有界参数或其他约束，低目标值本身不能作为“坐标正确”的证据。



计算诊断：相同预测下，平方残差可随共同尺度任意收缩；满秩并不能阻止它。

本次用无仿射参数BatchNorm和非零扰动幅度等稳定措施；这是**独立实现的补充约定**，不能说原文已经给出了它们。

3.8 “更多零项”不推出“总误差更低”

两种解的残差若为$(0,0,0,0,4,4)$与$(0,0,1,1,1,1)$，第一种有更多零项，但总误差8大于4。

附录A用匹配组对数量论证平方残差总和更小，需要额外控制非零项幅度。第06章给出同协方差、满秩扰动、可精确计算的旋转诊断。

3.9 总目标的实现不是唯一的

论文有行为损失和对比损失，实验还涉及自编码目标与基线，但没有把所有权重、归一化、约束处理写成唯一可执行规格。

本次登记：AE用重构；Pred用重构+交叉熵；CDC再加$0.2L_{\text{contrast}}$；所有方法共享结构、标准化、正则和轮次。它是可复算的独立方案，不是声称还原了缺失的作者代码。

04 | 从公式到能运行的算法：每个实现选择都摊开

4.1 作者明确提供了什么

附录B给出：合成数据20000条；70:15:15划分；VAE用于低层特征；合成瓶颈隐藏宽度4；行为预测头为单线性层；每个锚点5个候选；Adam和验证平台调学习率；50轮按验证损失选检查点。

半合成用20000条简介和3个LM，训练3轮，按验证真实因素DCI调瓶颈深度和宽度。没有概念真值的拒答实验复用半合成最佳超参数。

这仍不足以唯一决定学习率、VAE潜维度、KL权重、损失配比、轴搜索、扰动非零约束和归一化。

4.2 本次独立实现的固定协议

项目	合成实跑	文本实跑
样本	每设置20000	2400真实简介
随机种子	11、23、37	同左
低层模型	四个宽16的隐藏线性/ReLU模块构成VAE编码/解码路径	冻结DistilBERT-base最后层CLS
VAE潜维度	16，KL权重0.001	不再训练VAE
瓶颈	16→4→d	768→64→2
瓶颈标准化	BatchNorm，无可学习仿射参数	同左
重构头	d→16→标准化输入	2→16→标准化CLS
行为头	单线性层	单线性层
优化	Adam，lr=0.001，weight decay=0.0001	同左（不同于作者AdamW）
轮次	VAE50轮；每方法瓶颈50轮	每方法瓶颈50轮
约束权重	0.2；前10轮预热	同左
候选预算	每组12个锚点，每锚点5个候选	同左
轴覆盖	精确离散动态规划；连续参数梯度更新	同左
模型选择	验证目标，不看测试DCI	同左

所有均值、标准差只在训练集拟合。真实z不进入训练损失或模型选择，仅用于最后的监督评价。

4.3 对比项的实际计算

对组对$p=(k,l)$、候选轴r、共享幅度a_{pr}，记候选差v_{pij}。计算

$$K_{pr}=\frac{1}{N_a}\sum_i \min_{j\in\mathcal{J}_i}\left[\|v_{pij}\|^2-2a_{pr}v_{pij,r}+a_{pr}^2\right].$$

括号正是$\|v-ae_r\|^2$，不是额外近似。候选集合和锚点抽样才是对全数据搜索的近似。

固定轴分配时用自动求导更新模型及幅度；每轮收集K，重新选轴分配。候选最小值在并列处不可微，框架选择一个分支；随机连续点的梯度已用有限差分诊断。

4.4 怎样保证离散轴全覆盖

把已经覆盖的轴记成位掩码M。处理第p个组对时：

$$F_{p+1}(M\cup\{r\})=\min\{F_{p+1}(M\cup\{r\}),\ F_p(M)+K_{pr}\}.$$

起点是$F_0(\varnothing)=0$，终点要求M包含全部d条轴。复杂度$O(Pd2^d)$，适合$d=2,3$，不声称能直接扩到数千维。

这是给定当前代价矩阵时的精确离散解，**不是整个神经网络目标的全局最优解**。40个小矩阵上已与全部轴分配穷举一致。

4.5 非零幅度、方差与预热

我们把有效幅度绝对值限制至少0.1，并对原始瓶颈标准差低于0.25加惩罚，防止退化；梯度范数裁到10。前10轮先学重构/预测，再引入对比。

这些约定会改变可达解和训练轨迹。不能因为结果差就事后改权重直到表格好看，再称“复现成功”。本次所有预登记种子的结果全部报告。

4.6 三个基线/方法在比较什么

$$
\begin{aligned}
L_{\mathrm{AE}} &= L_{\mathrm{rec}} + L_{\mathrm{common}}, \\
L_{\mathrm{Pred}} &= L_{\mathrm{rec}} + L_{\mathrm{CE}} + L_{\mathrm{common}}, \\
L_{\mathrm{CDC}} &= L_{\mathrm{rec}} + L_{\mathrm{CE}} + 0.2L_{\mathrm{contrast}} + L_{\mathrm{common}}.
\end{aligned}
$$

共同项包括方差惩罚和优化器正则。AE的行为头未训练，因此其随机行为预测不报告为有效准确率。

三方法瓶颈训练轮次相同，但CDC单轮多做候选搜索，所以**轮次相同不等于运行时间相同**。每次耗时单独保存。

4.7 实际执行流程

固定协议、版本、种子
→ 生成/选取数据并保存划分
→ 训练VAE或提取冻结LM激活
→ 用同一初始化规则训练AE、Pred、CDC
→ 仅按验证目标选检查点
→ 保存各划分低维表示、模型、逐因素预测
→ 训练集拟合评价器，测试集算DCI/MCC
→ 汇总所有种子、重算每个数、绘图

实现入口为`experiments/cdc_core.py`、`run_synthetic.py`、`prepare_text.py`、`run_text.py`。公开证据包包含这些文件及数值证据；不包含下载的LM权重、原始人物简介或机器凭据。

4.8 复现声明的底线

本次没有取得官方补充代码，没有执行原规模7B/8B模型、真实拒答或SAE实验。网页的作者表格保持“原文报告”标记，本次新表保持“独立重实现/缩小实验”标记。两者不能拼成一张貌似全部重现的成绩单。

05 | 定理1完整推导：哪些条件才能推出仿射恢复

5.1 原文结论与需要核查的地方

原文定理1： 满足假设1，且最优满足公式(3)的编码器，可以恢复真实潜变量到可逆仿射变换。

附录A的路线是：交叉熵最优 → 类别概率相同 → logits相差一个公共项 → 堆叠方程并求逆。

这里有两个实质问题：公共归一化差通常依赖输入；$m > d$不自动保证矩阵满秩，可逆也不能直接用在长方形矩阵上。

下面给出**添加明确条件后的严谨版本**，不把它冒充原文已经写出的全部假设。

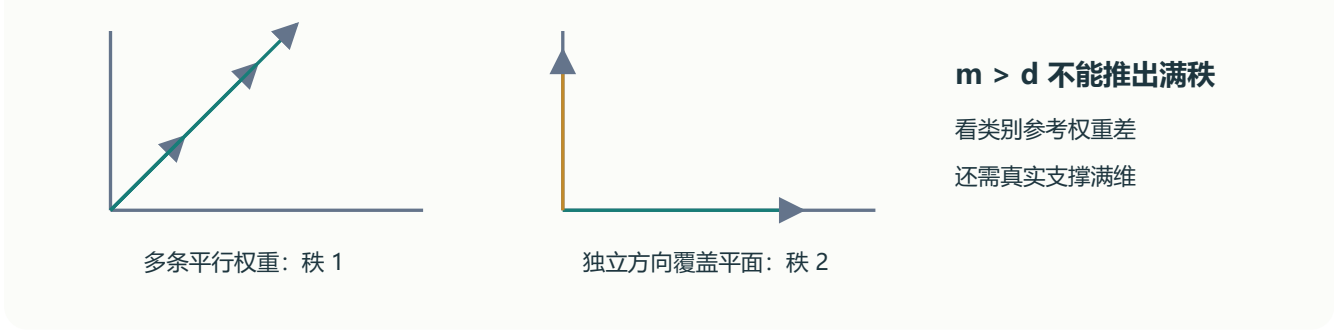
5.2 条件化命题

设真实概念$z(x) \in \mathbb{R}^d$，学习表示$f(x) \in \mathbb{R}^d$。假设：

1. 真实与学习条件概率均为线性logits softmax，可允许截距；
2. 训练类可实现真实条件概率，且总体交叉熵达到其最低值；
3. $z(x)$的支撑仿射张成$\mathbb{R}^d$；
4. 以一个参考类别作差，真实权重差矩阵B列秩为d。

则在相关支撑上，$f(x) = Az(x) + b$，其中A可逆。

至少需要$m - 1 \geq d$，但类别数足够只是容纳满秩的必要条件，不是满秩本身。



教学图：真正起作用的是类别参考权重差的独立方向，不只是类别数。

5.3 第一步：从交叉熵到正确概率

总体风险满足

$$\mathcal{R}(q) = \mathbb{E}_x H(p(\cdot \mid x)) + \mathbb{E}_x D_{\mathrm{KL}}(p(\cdot \mid x) \| q(\cdot \mid x)).$$

可实现且达到最优时，KL项几乎处处为0，故$q(c \mid x) = p(c \mid x)$。默认是分布意义的“几乎处处”；若要所有$x$成立，还需要连续性等条件延拓，不能自动升级。

5.4 第二步：用参考类别而不是丢掉归一化

真实logits为$w_c^\top z + \beta_c$，学习logits为$q_c^\top f + \alpha_c$。选类别0：

$$\log \frac{p(c \mid x)}{p(0 \mid x)} = (w_c - w_0)^\top z + \beta_c - \beta_0,$$

$$\log \frac{q(c \mid x)}{q(0 \mid x)} = (q_c - q_0)^\top f + \alpha_c - \alpha_0.$$

两者相等，堆叠$c = 1, \ldots, m-1$得到

$$Bz + \gamma = Qf + \eta. \qquad (\star)$$

其中$B, Q \in \mathbb{R}^{(m-1)\times d}$。所有偏移已明确成为**模型参数截距差**，不是把输入相关的log-sum-exp误当成常数。

5.5 第三步：为什么学习矩阵Q也满秩

任取支撑中的参考点x_0，用$(\star)$相减：

$$B[z(x) - z(x_0)] = Q[f(x) - f(x_0)].$$

因为真实支撑仿射满维，$z(x) - z(x_0)$张成d维；B列满秩，因此左侧张成维数d。右侧都位于Q的列空间，所以$\mathrm{rank}(Q) \geq d$。

而Q只有d列，因此$\mathrm{rank}(Q) = d$。

5.6 第四步：左逆求出A，再证明可逆

列满秩长方形矩阵有左逆

$$Q^{\dagger} = (Q^{\top}Q)^{-1}Q^{\top}, \qquad Q^{\dagger}Q = I_d.$$

左乘$(\star)$：

$$f = Q^{\dagger}Bz + Q^{\dagger}(\gamma - \eta) = Az + b.$$

由支撑差分张成全空间，还得到$QA = B$。于是

$$d = \mathrm{rank}(B) = \mathrm{rank}(QA) \le \mathrm{rank}(A) \le d.$$

所以A满秩、可逆。证毕。

额外观察： 若两边都严格无截距，参考log-odds方程没有常数项，可能得到更强的线性形式。本文保留仿射版本，以兼容实际带偏置分类头。

5.7 精确算例：左逆确实恢复原矩阵

取

$$B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}, \quad A = \begin{pmatrix} 2 & 1 \\ -1 & 3 \end{pmatrix}, \quad Q = BA^{-1}.$$

$\det A = 7$，且

$$Q = \frac{1}{7}\begin{pmatrix} 3 & -1 \\ 1 & 2 \\ 4 & 1 \end{pmatrix}.$$

符号计算给出$Q^{\dagger}B = A$，不是只在一个数值输入上“碰巧成立”。代码使用SymPy有理数精确运算。

5.8 反例：类别数多仍可不识别

令$d = 2, m = 4$，真实logits是

$$\ell_c(z) = c(z_1 + z_2), \qquad c = 0, 1, 2, 3.$$

它满足logit线性softmax，却只依赖一个组合$z_1 + z_2$。令

$$f(z) = \big(z_1 + z_2,\ (z_1 - z_2)^3\big).$$

用学习权重$q_c = (c, 0)$，对所有z，学习logits与真实logits完全相同，交叉熵达到相同最优；但f不是仿射映射，第二坐标Hessian一般非零。

这个f甚至保留了两维信息：由和及差的立方能恢复原坐标。因此问题不只是“编码器丢掉了一维”，而是分类概率根本没有约束另一维的坐标形状。

范围： 这是对“假设1单独足以推出定理1”这一表述的诊断；不声称它同时满足假设2并反驳所有后续结论。

5.9 读完定理1应带走什么

正确的核心思想是：足够丰富的**线性log-odds**可以把表征等价类压缩到仿射类。不能省略“足够丰富”的秩与支撑条件，也不能把实际有限训练直接等同于总体最优证明。

06｜定理2完整证明路线：可靠引理与尚未补齐的桥梁

6.1 原文目标

原文定理2： 假设1、2成立，满足公式(3)(4)的编码器恢复真实因素到尺度和置换，即$A = DP$。

为了看清哪些步骤成立，我们先假定第05章的条件已经保证

$$\hat{z} = Az + b, \qquad A\text{可逆}.$$

接下来只需把混合矩阵A限制成每行每列恰有一个非零数。

6.2 找对纯坐标配对时：原文(5)

如果确实有一对真实样本满足

$$z_j - z_i = b_r e_r, \quad b_r \neq 0,$$

并且学习表示在**同一对样本**上满足

$$\hat{z}_j - \hat{z}_i = c_s e_s, \quad c_s \neq 0,$$

代入仿射关系，平移b抵消：

$$A(b_r e_r) = c_s e_s \quad \Longrightarrow \quad Ae_r = \frac{c_s}{b_r} e_s. \tag{5}$$

Ae_r是A第r列，因此这一列只有第s项非零。PDF紧随公式的文字有比例方向笔误，正确比例以显示公式c_s/b_r为准。

6.3 条件化的单稀疏列引理：完整证明

命题： 若$A \in \mathbb{R}^{d\times d}$可逆，并且每个真实轴$r$都存在上述非零纯配对，且学到的**同一配对**差分单稀疏，则$A = DP$，D对角非零，P为置换矩阵。

证明：

1. 根据(5)，每一列都有且仅有一个非零项，记其行号为$s(r)$。
2. 若$r \neq t$却$s(r) = s(t)$，则两列都是同一个标准基向量的倍数，线性相关。
3. 可逆矩阵的列线性无关，故$s(r)$不能重复。
4. d列选取d个不同的行号，因此这些行号恰好构成置换。
5. 把非零幅度放入对角矩阵，得到$A = DP$。证毕。

这部分不需要靠枚举证明。脚本另外检查了162个三维有理数矩阵，只作为实现/直觉核验。

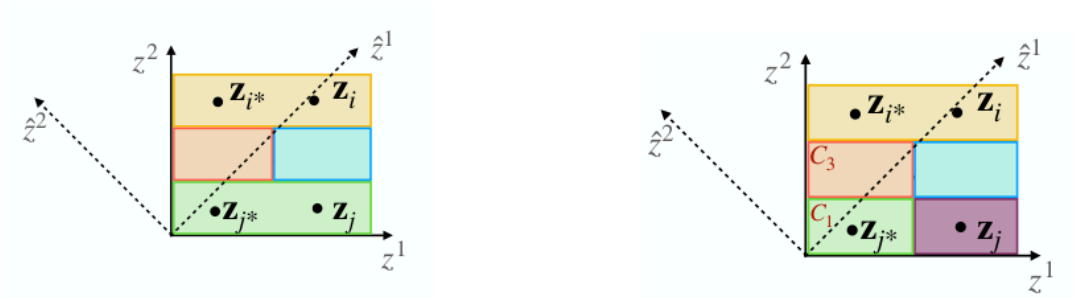
6.4 原文为什么还要写第二个分支

算法并不知道真实纯配对i^*, j^*。内层最小化可能选到另一个i，通过一个旋转混合后的轴也获得低残差。

原文尝试用必要条件排除这种“错配”。其思路是构造另一个真实点，使两个概念变化在学习坐标s上抵消：

$$b_r A_{sr} + c_u A_{su} = 0, \quad c_u = -b_r A_{sr} / A_{su}.$$

这样行为仍不同，但猜测的必要坐标s没有变化，企图产生矛盾。

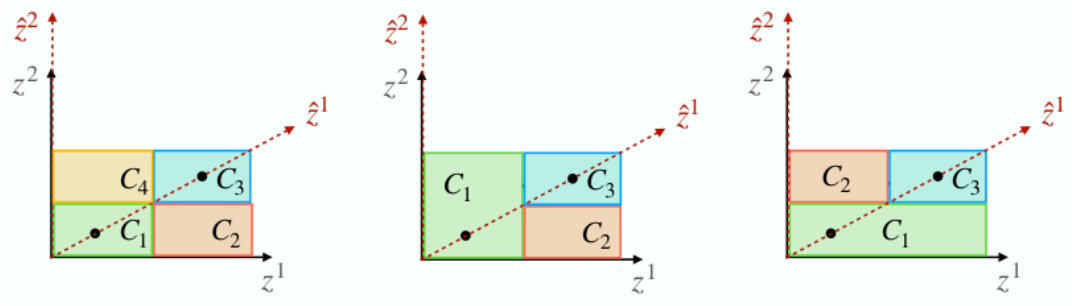


原图4节选（PDF第18页）：作者自己指出，构造矛盾所需的点可能不在相关行为组内。右图改用另一个组对，但一般充分条件还需明确。

需要的桥梁： 这个特定c_u对应的点必须真的存在于合法输入/正确行为组；而必要性首先定义在真实概念干预上，不能不经论证就把任意学习轴当成同样的必要概念。

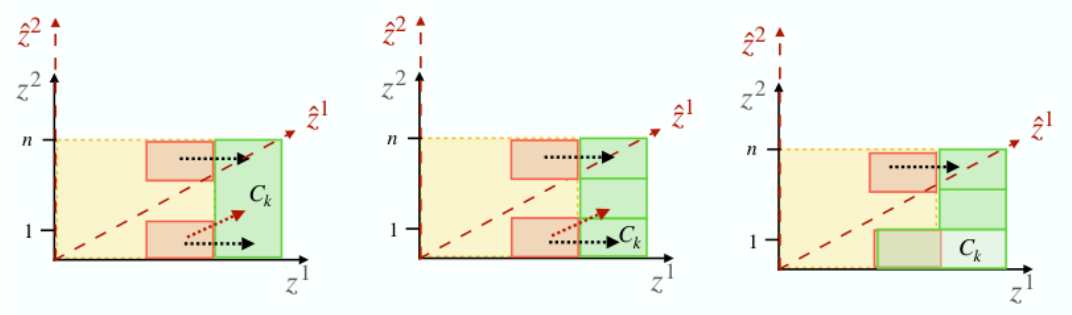
6.5 原文最后的匹配计数论证

附录A后半部分按组数归纳，主张正确轴有更多“匹配组对”，因此公式(4)更小。



原图5节选（PDF第18页）：基础情形包括一例正确轴与错轴匹配数相同的配置。因此“严格更多”本身需要足够组变化的附加条件。

原文列出添加一个组、添加多个组、合并组等归纳情况，比较沿真实轴与错轴的匹配数。



原图6节选（PDF第19页）：这是特定几何布局的计数直觉。要覆盖一般支撑、任意组形状和加权平方目标，还需要形式化条件。

即使某些布局的计数成立，**零残差项更多也不自动使非零残差之和更小。**公式(4)是平方误差总和，不是0/1匹配计数。

6.6 固定尺度的可计算旋转诊断

取四个组各只有一个点，位于$(\pm 1, \pm 1)$。对全部6个无序组对，最优单轴近似的平方残差为

$$\min_{r,a} \|v - ae_r\|^2 = \min(v_1^2, v_2^2).$$

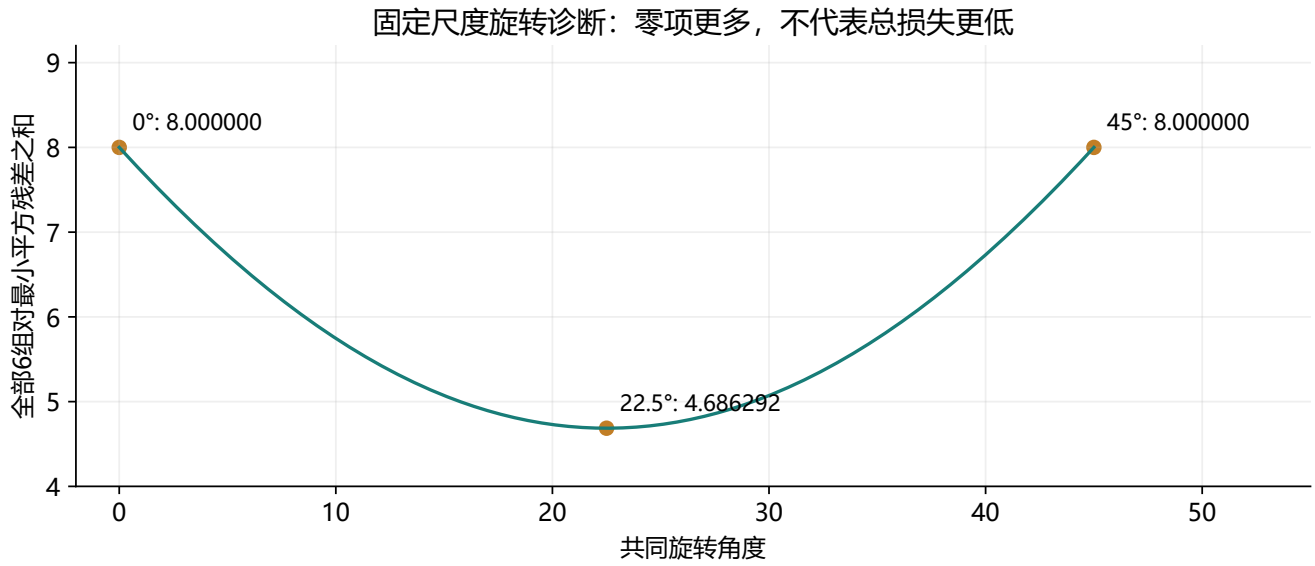
坐标共同旋转θ，限定$0 \le \theta \le \pi/4$。4条边各贡献$4\sin^2\theta$，2条对角各贡献$4(\cos\theta - \sin\theta)^2$，总损失

$$L(\theta) = 16\sin^2\theta + 8(\cos\theta - \sin\theta)^2 = 16 - 8\cos 2\theta - 8\sin 2\theta.$$

因此

$$L(0) = 8, \qquad L(\pi/8) = 16 - 8\sqrt{2} \approx 4.686292, \qquad L(\pi/4) = 8.$$

正确轴$\theta = 0$有4个零项；22.5度旋转没有零项，却损失更低。两者协方差都是单位阵，扰动仍可满秩，线性分类logits可以通过逆旋转保持一致。



实际计算图：精确表达式与NumPy计算相互核对。四点组是对“匹配数推出总平方损失”的诊断，不声称同时满足严格随机softmax与全部CDC定义。

6.7 尺度问题与平移问题

- 尺度：表征、扰动共同乘ϵ，分类权重反向缩放，预测不变但平方损失乘ϵ^2；满秩约束不能阻止它。
- 平移：任何b都在差分中抵消，所以公式(4)不能识别全局原点。严谨结论通常应写为$\hat{z} = DPz + b$，或先声明中心化。

本次用归一化避免显然的尺度收缩，但这不修复未知配对选择的完整理论保证。

6.8 能放心使用的结论与不能越过的边界

可严格证明： 在仿射恢复、每轴真实纯配对已可获得、且同一配对学成单稀疏这些明确条件下，得到尺度/置换形式。

原文仍需补充条件/论证： 从定义2得到观测纯配对；未知配对的选择必然正确；任意布局下计数比较成立；计数能控制平方总损失；尺度和非零扰动受控。



教学图：条件化引理成立，不代表未知配对算法已经获得无条件的全局保证。

这里提供的是对证明链的分段核查，不是作者正式勘误，也不以本次有限训练失败声称“所有可能补全版本均为假”。

07 | 评价指标与统计：每个数字究竟怎么算

7.1 MCC：最佳一一相关匹配

真实因素$z_1, \dots, z_d$，学习特征$f_1, \dots, f_d$。先在测试集计算Pearson相关矩阵，再取绝对值、用线性分配求最佳一一对应：

$$\mathrm{MCC} = \max_{\pi} \frac{1}{d} \sum_{i=1}^{d} |\,\mathrm{Corr}(f_i, z_{\pi(i)})|.$$

允许符号翻转和坐标置换，不允许任意旋转后再计算。独立同方差因素旋转45度，信息未丢，但逐轴相关约$1/\sqrt{2}$。

过完美地把所有坐标做非线性单调变换，Pearson相关也未必等于1。这是MCC与更宽泛可识别关系的边界。

7.2 DCI的重要性矩阵从哪里来

在**训练集**拟合评价器预测每个真实因素，得到特征重要性矩阵$R_{ij} \geq 0$：第i个学习特征对第j个真实因素的重要性。

本次使用100棵、深度3、固定种子的梯度提升树：连续因素用回归树，离散因素用分类树。它是明确的评价约定，不声称作者使用完全同一配置。

7.3 D：每个特征是否专一

按行归一化

$$p_{ij} = \frac{R_{ij}}{\sum_j R_{ij}}, \quad D_i = 1 + \frac{\sum_j p_{ij} \log p_{ij}}{\log d}, \quad D = \sum_i \frac{\sum_j R_{ij}}{\sum_{a,b} R_{ab}} D_i.$$

约定$0 \log 0 = 0$。行$(1, 0)$熵为0，专一性1；行$(0.5, 0.5)$熵最大，专一性0。

7.4 C：每个因素是否集中

按列归一化$q_{ij} = R_{ij} / \sum_i R_{ij}$，学习特征数为$\hat{d}$：

$$C_j = 1 + \frac{\sum_i q_{ij} \log q_{ij}}{\log \hat{d}}, \quad C = \sum_j \frac{\sum_i R_{ij}}{\sum_{a,b} R_{ab}} C_j.$$

如果两个特征复制同一个真实因素，D可以高而C低。若维度只有1，公式分母为0，需要另行约定；本次实际实验均至少二维，不受这个边界影响。



7.5 三个可手算的矩阵

$$R_1 = I_2, \qquad R_2 = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}, \qquad R_3 = \begin{pmatrix} 0.8 & 0.2 \\ 0.2 & 0.8 \end{pmatrix}.$$

分别得到$(D, C) = (1, 1), (0, 0), (0.2780719, 0.2780719)$。这里的分数从熵计算，不是直接把矩阵对角均值当作结果。

7.6 I：必须说明具体预测分数

连续实验：对每个因素算测试R^2再平均：

$$R_j^2 = 1 - \frac{\sum_n (z_{nj} - \hat{z}_{nj}^{\text{eval}})^2}{\sum_n (z_{nj} - \overline{z}_j)^2}, \quad I = \frac{1}{d} \sum_j R_j^2.$$

注意$\hat{z}^{\text{eval}}$是评价器的因素预测，不是瓶颈本身。R^2可为负，本次不截断。

离散文本实验：I是两个因素测试准确率的平均。一个二分类因素和一个三分类因素等权平均，不等于把两者的类别全合成一个类别来算准确率。

原文未给出足够细的评价器实现，因此其I=1.0不能作为与本地R^2逐位对齐的保证。

7.7 保存什么才能真正重算

每次实跑保存：测试样本ID、真实因素、学习特征、行为真值与行为预测；全部划分的低维特征；逐因素评价预测；重要性矩阵；模型检查点；训练轨迹；协议和散列。

检查点指解释瓶颈及预测/重构头，不是完整LM；合成VAE仅保存轨迹和重训协议，未另存权重。重算发布指标无需重训VAE，若从原始x重建低层特征则需要按种子重训。

验证脚本从这些原始数组重算MCC、D、C、I及行为准确率，再与JSON记录比较，误差超阈值即失败。不是仅检查“程序退出码为0”。

真实简介文本不进入公开证据包；只发布可重新获取的数据版本、行号和派生数值。

7.8 三个种子的均值和SD

对同一设置同一方法的三个值r_1, r_2, r_3，

$$\overline{r} = \frac{1}{3}\sum_{s} r_s, \qquad s = \sqrt{\frac{\sum_s (r_s - \overline{r})^2}{3-1}}.$$

报告“均值±样本SD”。本次合成的种子同时改变数据生成、划分与初始化，因此这是**整个协议的跨运行波动**，不是只隔离初始化的方差。

文本实验固定同一份2400条简介，种子改变划分和初始化；三个测试集可能重叠，不能把所有测试预测简单当作独立重复。

7.9 显著性只作为探索性计算

作者把同一测试集分5份，作独立t检验。它不能替代5次独立训练；相同测试块上的方法也有配对结构。没有原始重复分数，就无法从四舍五入均值重算原文p值。

本次额外计算同种子CDC减Pred的3个配对差，给出探索性双侧配对t检验，并对7种设置×4项指标的28个比较统一作Holm校正。$n = 3$非常小、文本重复还共享数据；这些p值不作为总体显著性的强证据。

不论有无显著星号，必须同时看效果大小、逐种子值、失败设置和与作者实现的差异。

08 | 作者的实验与结果：看原图，但不冒充已复现

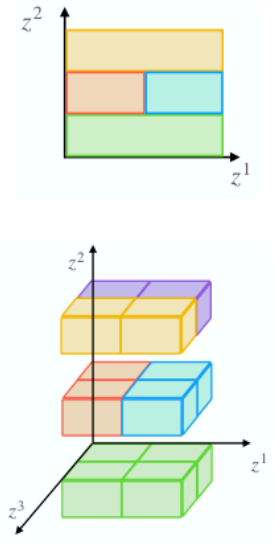
> **本章是原文报告。** 表中数字来自正式PDF第7页，保存在 `source/reported_tables.json`。
> 没有取得作者原始预测和补充代码，所以不是本次重新计算的成绩；新增实跑见第09章。

8.1 合成：已知真实因素，控制混合复杂度

作者从高斯分布采样二维/三维z，按行为规则分组，再用线性、非线性稀疏、非线性稠密函数得到x。VAE产生$g(x)$，再训练解释瓶颈。

“稀疏混合函数”说的是每个观测分量依赖较少因素；“单稀疏CDC”说的是组间变化。它们是不同的稀疏性。

Table 1: Synthetic data. *(Left):* Example of data with $d = 2$ (top) and $d = 3$ (bottom) latent factors. *(Right):* Disentanglement (D), Completeness (C), Informativeness (I), and Mean Correlation Coefficient (MCC) scores with latent dimension $d = 2$ (top; shaded) and $d = 3$ (bottom; unshaded).[4]



Mixing fn	Method	MCC	D	C	I
Linear	Autoencoding	0.76	0.30	0.36	1.0
	Autoenc+Pred	0.60	0.21	0.21	1.0
	Our constraints	**0.99**	**1.0**	**1.0**	1.0
Non-linear, sparse	Autoencoding	0.81	0.24	0.33	1.0
	Autoenc+Pred	0.72	0.0	0.0	1.0
	Our constraints	**0.91**	**0.97**	**0.97**	1.0
Non-linear, non-sparse	Autoencoding	0.67	0.0	0.0	1.0
	Autoenc+Pred	0.76	0.02	0.02	1.0
	Our constraints	**0.92**	**0.90**	**0.92**	1.0
Linear	Autoencoding	0.77	0.34	0.35	1.0
	Autoenc+Pred	0.65	0.23	0.31	0.87
	Our constraints	**0.94**	**0.99**	**0.99**	1.0
Non-linear, sparse	Autoencoding	0.74	0.19	0.25	1.0
	Autoenc+Pred	0.77	0.54	0.51	1.0
	Our constraints	**0.90**	**0.92**	**0.95**	1.0
Non-linear, non-sparse	Autoencoding	0.78	0.51	0.60	1.0
	Autoenc+Pred	0.86	0.54	0.59	1.0
	Our constraints	**0.89**	**0.89**	**0.89**	1.0

原表1（PDF第7页）：颜色是作者设定的行为组。右表全部为原文报告，粗体是作者显著性标记，不表示本次重新计算了p值。

作者报告CDC的D在六种设置中为1.00、0.97、0.90、0.99、0.92、0.89。它说明作者实现的受控实验有很强的逐轴恢复效果，不能从中直接推出任意真实LM或任意分组也成立。

二维高斯的均值/方差、精确分组阈值、完整三维分组代码、评价器细节未充分给出。本次把这些缺口列入独立约定，没有按作者表反向调参。

8.2 半合成：真实文本，人工行为标签

作者使用20000条BiasBios简介，真实因素是二元性别与高/中/低职业收入等级。收入等级来自职业男性收入中位数的1/3、2/3分位数，行为由人工规则模拟。

作者测试DistilBERT-base、Qwen2-7B和Llama-3.1-8B；本次并未按这些原规模逐一执行。

Table 2: Disentanglement (D), Completeness (C), Informativeness (I), and Mean Correlation Coefficient (MCC) scores on semi-synthetic data.[4]

Model	Method	MCC	D	C	I
Distilbert-base	Autoencoding	0.17	0.01	0.01	0.57
	Autoenc+Pred	0.32	0.18	0.20	0.85
	Our constraints	**0.85**	**0.91**	**0.92**	**0.99**
Qwen2-7B	Autoencoding	0.32	0.01	0.04	0.57
	Autoenc+Pred	0.69	0.06	0.06	0.83
	Our constraints	**0.79**	**0.80**	**0.84**	**0.97**
Llama-3.1-8B	Autoencoding	0.06	0.0	0.0	0.49
	Autoenc+Pred	0.54	0.05	0.11	0.84

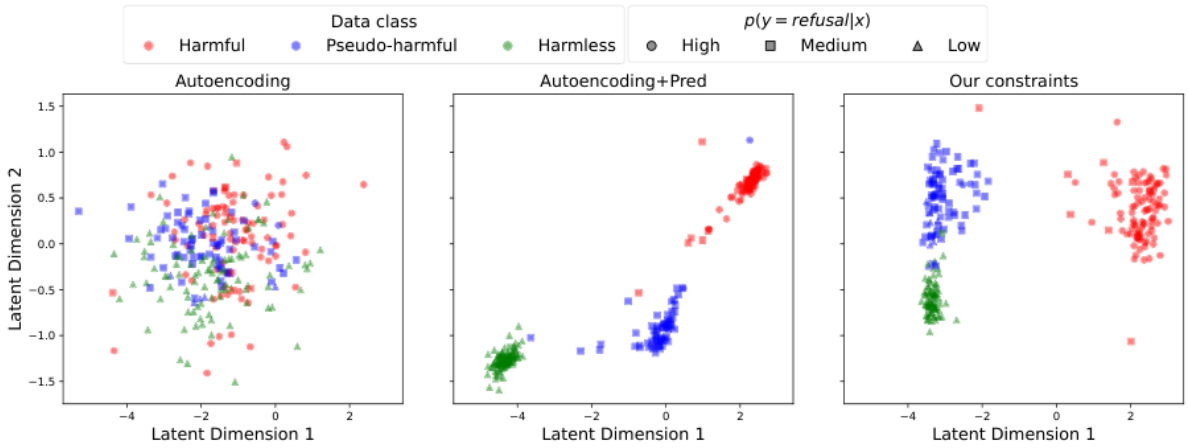
原表2（PDF第7页）：作者报告DistilBERT、Qwen、Llama的CDC D为0.91、0.80、0.86；本次缩小文本实验不能替代这张表。

这里最重要的对照是：行为预测帮助保留相关因素，但加入作者约束后D/C显著提高。仍要记住标签是模拟的，所以不是证明这些LM自然具有同样的收入偏见或相同内部因果机制。

8.3 拒答案例：没有概念真值时怎么解释

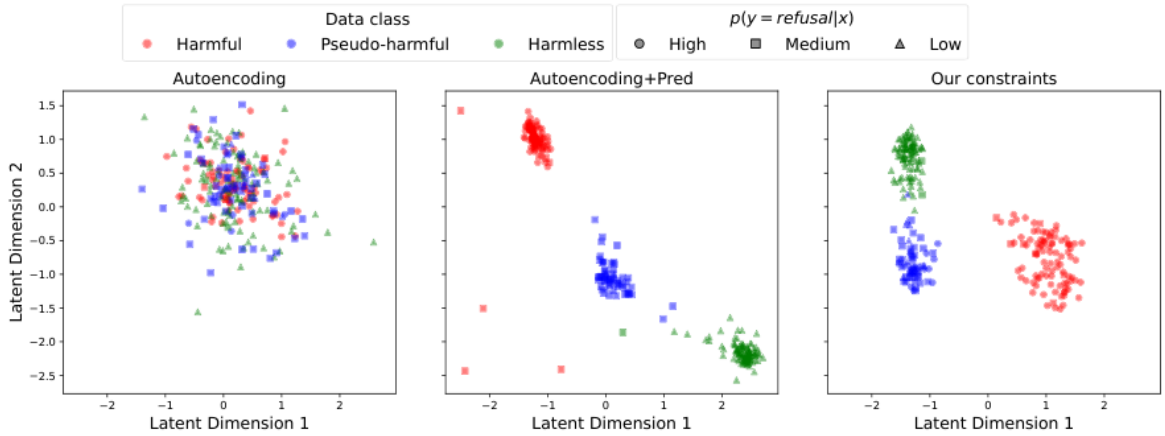
作者取有害、无害、伪有害三类提示各500条。行为分组来自拒答概率的高/中/低，不直接使用这些提示类型标签训练解释器。

拒答概率基于常见拒答开头，如“I am sorry”和“I cannot”。这是一个行为测量代理：可能漏掉其他措辞，也可能把普通表达误算为拒答。完整复现需要明确tokenization、序列概率合并与聚类细节。



原图2（PDF第8页）：颜色是真实提示类型，形状是拒答概率组。右图呈近轴对齐，被作者解释为伤害性与主题；没有概念真值和实际干预检验时，这仍是案例解释而非正式因果鉴定。

读图顺序：先看颜色（任务类型），再看形状（行为），最后看是否沿单轴分开。中图已把类型分开，但方向混合；右图看起来更接近“一个轴对应一种差异”。



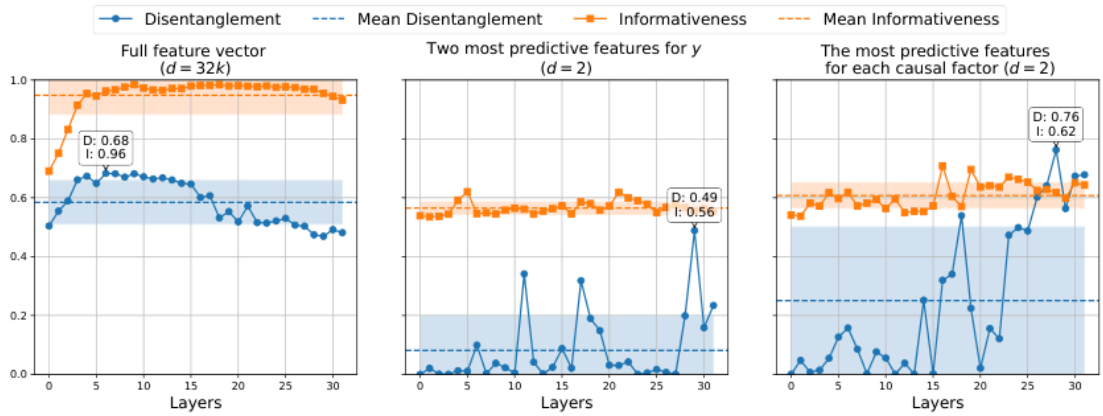
原图7（PDF第21页，附录C）：作者报告Qwen也出现类似结构。本次没有运行此模型，未复制其点坐标或拒答概率。

8.4 与SAE比较的三种评价

作者取LlamaScope残差流的32层×2种宽度，共64个SAE；整个资源另包含其他子层，不能把“使用64个”误读成“资源仅有64个”。

1. **全特征：** 看32k/128k特征整体保留多少因素信息。
2. **行为相关top-2：** 先线性预测c，选最有用的两个特征，与本文二维瓶颈比较。

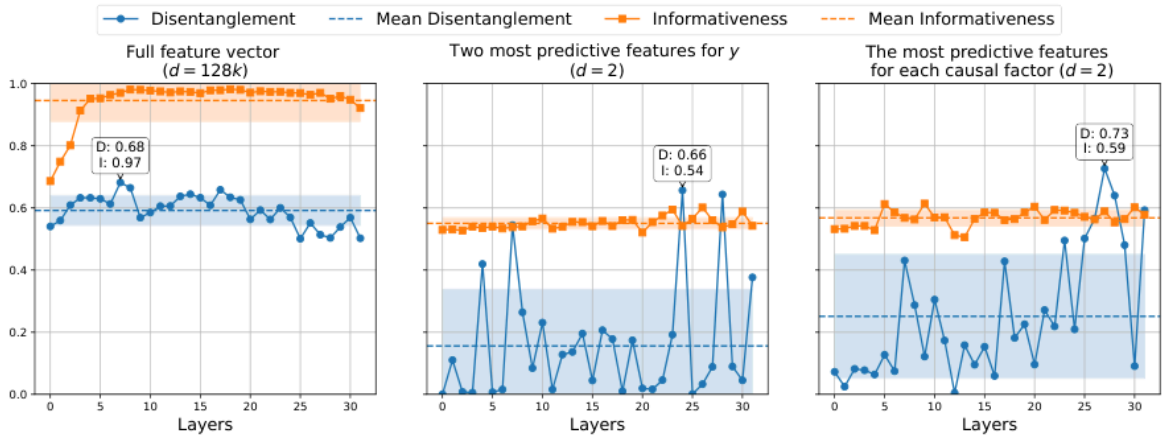
3. **真值相关top-2上限：** 直接用每个真实因素训练分类器，各选一个最有用特征；这额外用了概念标签，是上限分析。



原图3（PDF第8页）：三列是三种不同选择规则。虚线为层间均值，阴影为±1 SD；并不代表本次独立重新训练SAE。

作者报告全32k特征$I = 0.95 \pm 0.07$、$D = 0.58 \pm 0.07$；行为top-2后$I = 0.57 \pm 0.02$、$D = 0.08 \pm 0.12$；真值top-2的最高D为0.76，对应I为0.62。

这说明分布式大字典的信息可能不能压成两条现成特征。它不是“SAE完全没有这些信息”：全特征I很高。SAE也没有与CDC完全相同的行为目标，所以需要区分任务差异与表示质量差异。



原图8（PDF第21页）：作者报告128k宽度结论相似。图上的逐层精确数值未取得，不从图片读近似像素值冒充原始数据。

8.5 作者使用的算力

Table 3: Compute resources for different experiments. All runtimes were consistent across our method and the two baseline approaches.

Data setting	Model	Compute resources	Approx. time
Synthetic	Feedforward NN	4 CPU, 32 GB	20 minutes
Semi-synthetic	DistilBert-base	1 GPU, 4 CPU, 32 GB	45 minutes
Semi-synthetic	Qwen2-7B	4 GPU, 16 CPU, 256 GB	17 hours
Semi-synthetic	Llama-3.1-8B	4 GPU, 16 CPU, 256 GB	17 hours
Non-synthetic	Qwen2-7B	4 GPU, 16 CPU, 256 GB	2.25 hours

原表3（PDF第20页）：7B/8B半合成实验使用4GPU、256GB内存、约17小时；这是作者报告，不是本机计时。

本机约16GB内存且无CUDA；所以本次选择透明的CPU缩小实验，不伪装成同规格复现，也没有自动租用GPU。

8.6 能与不能从原表重算什么

- 可以：抄录校验；对已四舍五入分数做明确标记的算术差。
- 不可以：还原逐样本预测、准确p值、随机种子方差、全部模型检查点、图中每个点坐标。
- 不可以：根据均值自行补造误差条，再称经过复现。

本次公开`reported_tables.json`和来源页码用于追踪；新增表只从实际日志生成。两类证据有清晰的分界。

09 | 本次实跑：全部结果、失败设置与可重算证据

> **独立重实现/缩小实验，不是作者官方代码复现。** 未取得补充代码；原论文7B/8B、真实拒答、SAE原实验未执行。下面新增数字来自实际运行，作者数字见第08章。

9.1 实际运行规模与环境

- CPU实跑；本机约16GiB内存、10核Xeon，无CUDA；未购买云算力、未调用付费模型API。
- 18份合成数据集，各20000样本；6设置×3方法×3种子=54次瓶颈训练，另有18次共享VAE预训练。
- 2400条真实简介，768维冻结DistilBERT特征，3方法×3种子=9次训练；训练/验证/测试为1680/360/360。
- Python、库、数据与模型提交版本、数据SHA256及全部实现约定保存在协议中。

模型只按验证目标选检查点；没有根据最终MCC/DCI改变权重、结构或挑种子。为了补存全部评价器预测和模型检查点，另以完全相同协议重新执行；两轮原始结果均保留，并逐项比较指标。

9.2 合成结果：均值 ± 样本SD

I为连续因素的平均测试R^2，未截断。不同设置分开报告，不把相关的四个指标混成一个“综合胜率”。

2:linear

方法	MCC	D	C	I
AE 重构	0.940 ± 0.039	0.532 ± 0.209	0.533 ± 0.209	0.999 ± 0.000
Pred 预测	0.701 ± 0.022	0.019 ± 0.019	0.031 ± 0.028	0.976 ± 0.026
CDC 独立实现	0.777 ± 0.042	0.119 ± 0.089	0.133 ± 0.093	0.974 ± 0.025

2:sparse

方法	MCC	D	C	I
AE 重构	0.779 ± 0.162	0.243 ± 0.333	0.245 ± 0.333	0.928 ± 0.119
Pred 预测	0.690 ± 0.017	0.030 ± 0.029	0.051 ± 0.031	0.952 ± 0.063
CDC 独立实现	0.746 ± 0.034	0.061 ± 0.021	0.082 ± 0.020	0.949 ± 0.063

2:dense

方法	MCC	D	C	I
AE 重构	0.660 ± 0.206	0.231 ± 0.265	0.285 ± 0.226	0.856 ± 0.093
Pred 预测	0.700 ± 0.168	0.152 ± 0.216	0.215 ± 0.187	0.927 ± 0.052
CDC 独立实现	0.791 ± 0.049	0.275 ± 0.152	0.291 ± 0.164	0.901 ± 0.085

3:linear

方法	MCC	D	C	I
AE 重构	0.810 ± 0.130	0.399 ± 0.255	0.400 ± 0.255	0.996 ± 0.003
Pred 预测	0.755 ± 0.031	0.430 ± 0.146	0.437 ± 0.141	0.964 ± 0.011
CDC 独立实现	0.818 ± 0.035	0.410 ± 0.118	0.423 ± 0.118	0.969 ± 0.010

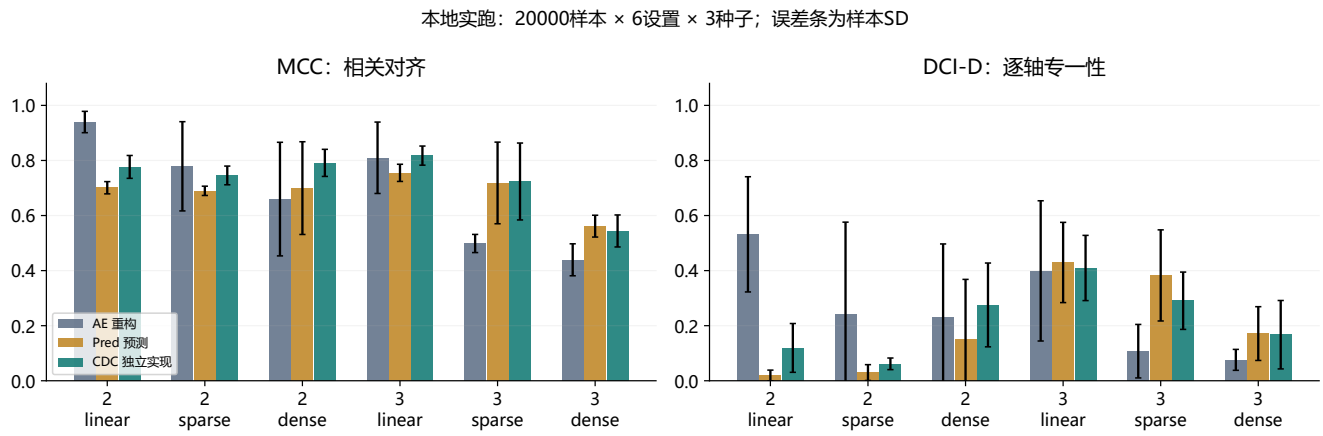
3:sparse

方法	MCC	D	C	I
AE 重构	0.498 ± 0.033	0.107 ± 0.097	0.126 ± 0.086	0.720 ± 0.074
Pred 预测	0.718 ± 0.148	0.383 ± 0.165	0.392 ± 0.173	0.873 ± 0.117
CDC 独立实现	0.724 ± 0.140	0.291 ± 0.104	0.298 ± 0.108	0.878 ± 0.116

3:dense

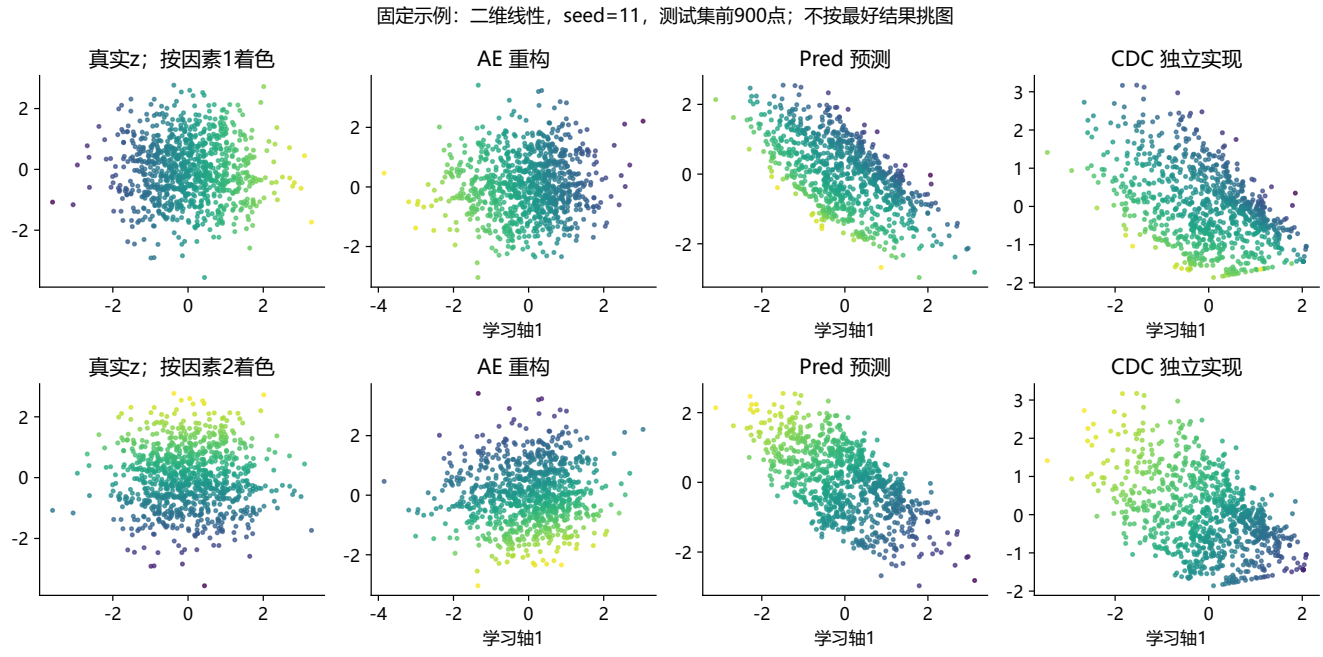
方法	MCC	D	C	I
AE 重构	0.439 ± 0.058	0.076 ± 0.038	0.102 ± 0.072	0.729 ± 0.029

方法	MCC	D	C	I
Pred 预测	0.561 ± 0.040	0.171 ± 0.098	0.215 ± 0.096	0.692 ± 0.024
CDC 独立实现	0.544 ± 0.058	0.167 ± 0.124	0.193 ± 0.130	0.675 ± 0.022

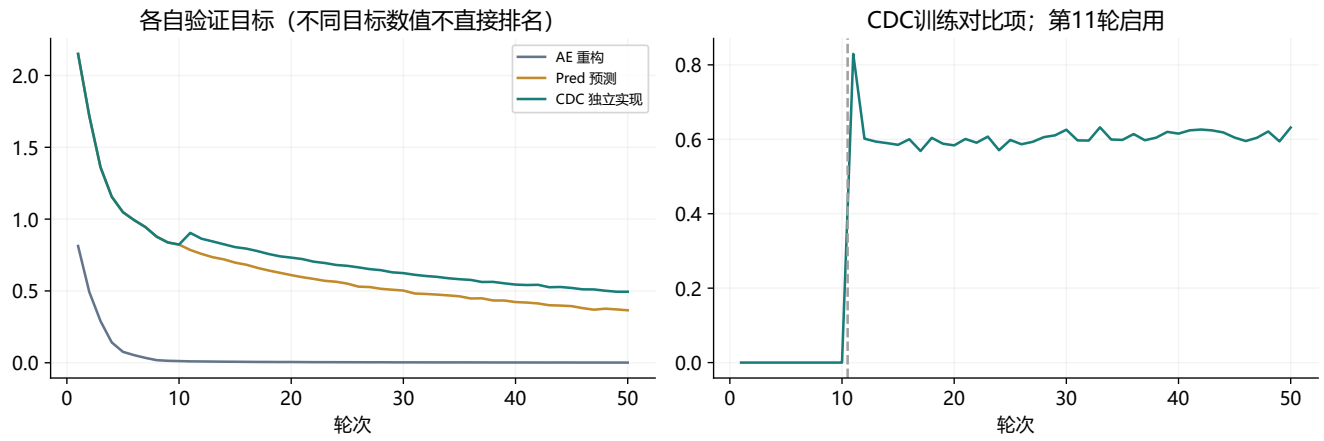


本地实跑计算图：全部预登记种子；误差条为样本SD，不是95%置信区间。

结论不是“成功复现作者表1”。 CDC相对Pred在部分设置改善，但没有在所有设置/指标占优；AE在部分二维设置反而更好。独立实现的归一化、共享平移近似、未披露的作者细节、VAE信息损失和有限优化都可能影响结果，当前数据不能确定哪一项是主因。



本地测试预测绘图：按预先固定seed=11展示，不按最好分数挑图；颜色是用于评价的真实因素，不曾作为概念训练标签。



实际保存的逐轮日志：AE、Pred、CDC的目标项不同，验证数值不可直接横向作为效果排名。训练收敛也不代表总体理论最优。

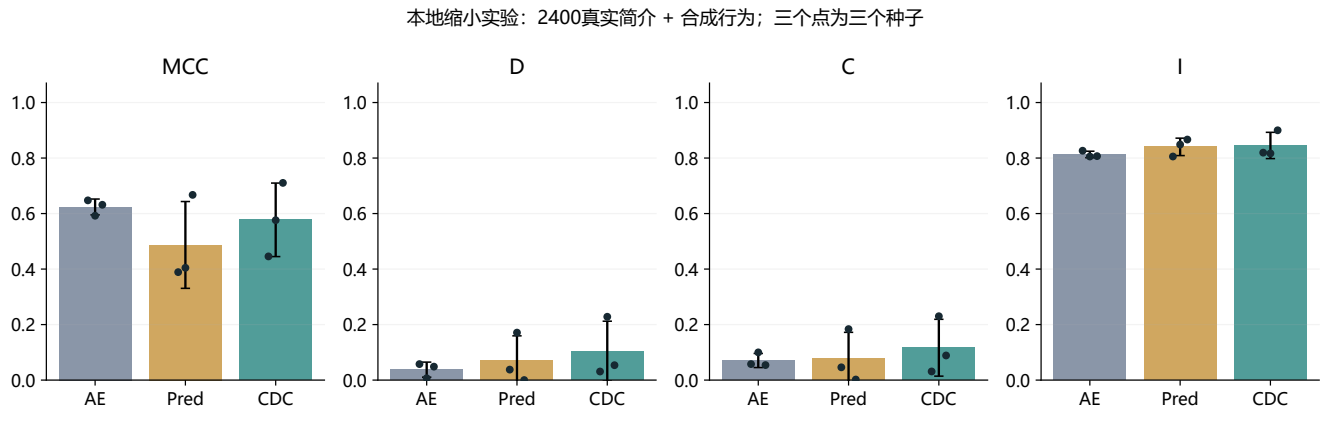
9.3 真实简介半合成：均值 ± 样本SD

方法	MCC	D	C	I
AE 重构	0.624 ± 0.029	0.038 ± 0.027	0.071 ± 0.025	0.813 ± 0.012
Pred 预测	0.487 ± 0.156	0.070 ± 0.090	0.077 ± 0.095	0.840 ± 0.031
CDC 独立实现	0.577 ± 0.132	0.104 ± 0.108	0.117 ± 0.102	0.845 ± 0.047

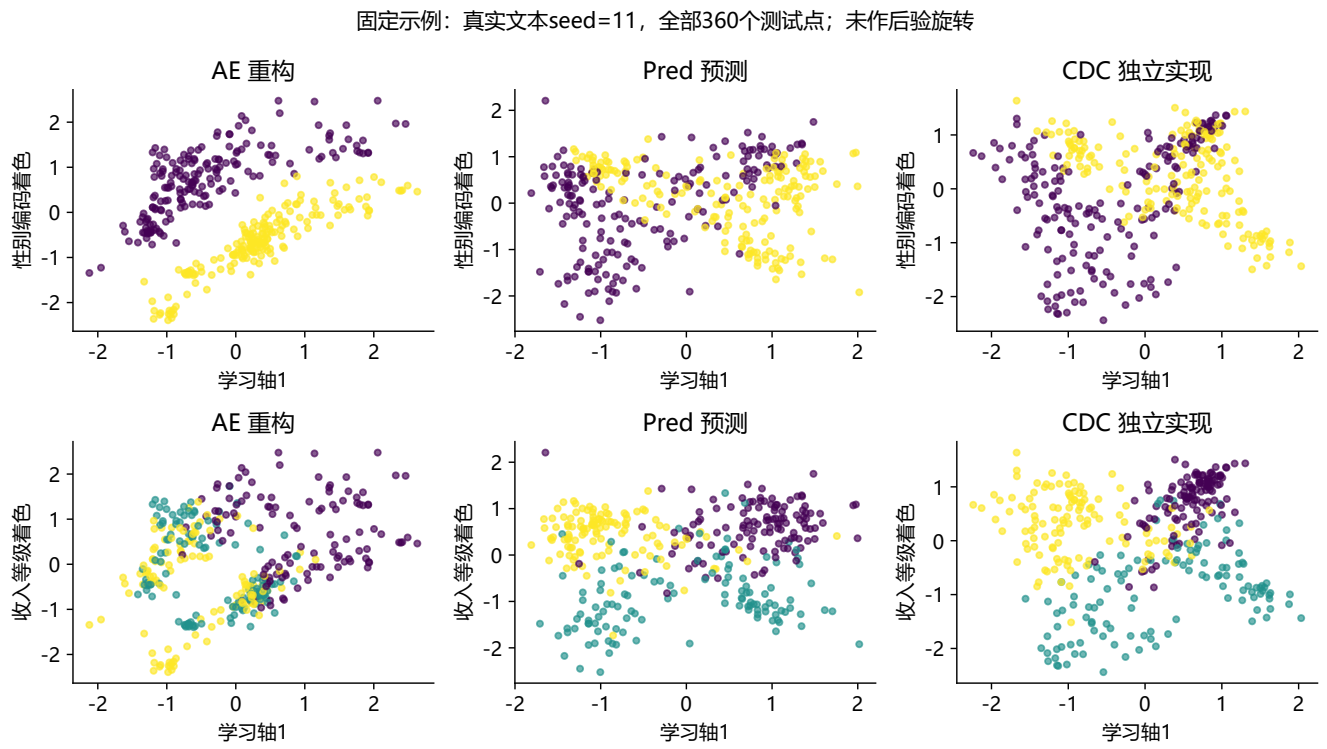
I是性别编码与收入等级的平均测试分类准确率。使用公开Bias in Bios镜像的固定提交，模型为固定提交的distilbert-base-uncased，safetensors加载且不运行远程自定义代码。

与作者表2的差异： 2400而非20000条；只选6种职业，收入等级使用明确的固定分组，不是重新下载劳工统计后算薪资分位数；冻结最后层CLS、最大长度96；只训练小解释网络；固定结构和50轮而非原文3轮与DCI网格调参。

六职业分组：accountant/nurse→中，attorney/physician→高，painter/teacher→低。每职业、每性别编码抽200条，共12个单元。模拟四类行为只由性别和收入等级生成，**不是观察到DistilBERT真的作出了收入判断。**



本地实跑：条为均值，黑点为各种子，误差条为样本SD。不能用本图冒充作者的原规模DistilBERT分数。



全部360个测试点；没有为了视觉效果作后验旋转。能看出因素信息不等于每个轴都已对齐。

整体上，文本I较高但D仍低、种子间不稳定；这恰好说明“保留因素信息”和“逐轴识别”不同。没有取得作者原代码，不能把差异归结为论文方法必然无效，也不能把本地某次改善吹成复现成功。

9.4 每次运行的原始分数

下面保留全部63次瓶颈训练，避免只给均值掩盖失败种子。更多小数位和逐样本预测在计算证据包中。

设置	种子	方法	MCC	D	C	I
2:linear	11	ae	0.959736	0.628777	0.629949	0.999192
2:linear	11	pred	0.678194	0.000005	0.000580	0.988861
2:linear	11	cdc	0.772087	0.093732	0.115495	0.987391
2:linear	23	ae	0.964196	0.674776	0.674776	0.998617
2:linear	23	pred	0.722648	0.038939	0.056020	0.945379
2:linear	23	cdc	0.820214	0.217790	0.233069	0.945439
2:linear	37	ae	0.894920	0.291600	0.292865	0.998489
2:linear	37	pred	0.701993	0.018611	0.034920	0.992519
2:linear	37	cdc	0.737562	0.046197	0.049605	0.989690
2:sparse	11	ae	0.955805	0.624384	0.625916	0.997882
2:sparse	11	pred	0.684406	0.004762	0.024030	0.987770
2:sparse	11	cdc	0.780313	0.073427	0.088813	0.978191
2:sparse	23	ae	0.742866	0.009251	0.010848	0.995668
2:sparse	23	pred	0.676166	0.061187	0.085477	0.879231
2:sparse	23	cdc	0.744222	0.073905	0.098203	0.876933
2:sparse	37	ae	0.637767	0.094675	0.099143	0.791502
2:sparse	37	pred	0.708613	0.023164	0.043953	0.987685
2:sparse	37	cdc	0.712401	0.037145	0.059407	0.991860
2:dense	11	ae	0.459744	0.094837	0.212602	0.827318
2:dense	11	pred	0.870963	0.399757	0.423316	0.938625
2:dense	11	cdc	0.844221	0.382329	0.420611	0.947186
2:dense	23	ae	0.647661	0.062327	0.103989	0.781028
2:dense	23	pred	0.534346	0.002623	0.158683	0.870141
2:dense	23	cdc	0.782517	0.342586	0.345892	0.802584
2:dense	37	ae	0.871777	0.537297	0.537804	0.960792
2:dense	37	pred	0.693527	0.054080	0.061707	0.972808
2:dense	37	cdc	0.746981	0.101141	0.106685	0.953743
3:linear	11	ae	0.928148	0.653162	0.655159	0.997764
3:linear	11	pred	0.768717	0.500509	0.503109	0.966117

设置	种子	方法	MCC	D	C	I
3:linear	11	cdc	0.791901	0.396511	0.410513	0.980309
3:linear	23	ae	0.830020	0.399926	0.400459	0.996813
3:linear	23	pred	0.719306	0.261927	0.275247	0.951193
3:linear	23	cdc	0.803919	0.298124	0.312452	0.966402
3:linear	37	ae	0.671182	0.143888	0.144908	0.992202
3:linear	37	pred	0.777012	0.526101	0.534021	0.973629
3:linear	37	cdc	0.857125	0.533940	0.546620	0.959908
3:sparse	11	ae	0.470998	0.219576	0.222503	0.687205
3:sparse	11	pred	0.799013	0.492332	0.512198	0.905572
3:sparse	11	cdc	0.800906	0.370706	0.382359	0.926511
3:sparse	23	ae	0.489345	0.049406	0.094447	0.668523
3:sparse	23	pred	0.547283	0.192259	0.193537	0.743264
3:sparse	23	cdc	0.562485	0.172959	0.176791	0.746120
3:sparse	37	ae	0.535044	0.053273	0.059599	0.804824
3:sparse	37	pred	0.808786	0.463040	0.470206	0.969551
3:sparse	37	cdc	0.807616	0.328108	0.335865	0.962045
3:dense	11	ae	0.375912	0.055362	0.055851	0.753020
3:dense	11	pred	0.576729	0.211180	0.271828	0.701160
3:dense	11	cdc	0.543545	0.233583	0.243829	0.668748
3:dense	23	ae	0.489919	0.119774	0.183980	0.697330
3:dense	23	pred	0.516488	0.060115	0.104683	0.664326
3:dense	23	cdc	0.486099	0.023912	0.045512	0.657626
3:dense	37	ae	0.451956	0.052585	0.064822	0.735803
3:dense	37	pred	0.591191	0.242785	0.268651	0.709772
3:dense	37	cdc	0.602335	0.244222	0.290310	0.699583
真实文本	11	ae	0.647565	0.057685	0.057703	0.826389
真实文本	11	pred	0.388967	0.037764	0.046021	0.805556
真实文本	11	cdc	0.445635	0.030911	0.031104	0.819444
真实文本	23	ae	0.592170	0.006713	0.099847	0.805556

设置	种子	方法	MCC	D	C	I
真实文本	23	pred	0.404582	0.171041	0.183754	0.848611
真实文本	23	cdc	0.576097	0.228163	0.230098	0.816667
真实文本	37	ae	0.631635	0.048421	0.054126	0.806944
真实文本	37	pred	0.667319	0.000123	0.002023	0.866667
真实文本	37	cdc	0.710504	0.053665	0.088693	0.900000

9.5 探索性配对差和多重校正

CDC减Pred，同一设置同一种子配对。双侧t检验n=3；同一组28个比较作Holm校正。正差不自动显著，显著也不证明普遍可识别。

设置	指标	平均差 CDC−Pred	原始p	Holm校正p
2:linear	MCC	0.075676	0.063756	1.000000
2:linear	DCI_D	0.100055	0.149648	1.000000
2:linear	DCI_C	0.102216	0.163241	1.000000
2:linear	DCI_I	-0.001413	0.232558	1.000000
2:sparse	MCC	0.055917	0.176861	1.000000
2:sparse	DCI_D	0.031788	0.226909	1.000000
2:sparse	DCI_C	0.030988	0.208439	1.000000
2:sparse	DCI_I	-0.002567	0.584400	1.000000
2:dense	MCC	0.091628	0.378285	1.000000
2:dense	DCI_D	0.123199	0.379054	1.000000
2:dense	DCI_C	0.076494	0.311929	1.000000
2:dense	DCI_I	-0.026021	0.362676	1.000000
3:linear	MCC	0.062637	0.086833	1.000000
3:linear	DCI_D	-0.019988	0.686409	1.000000
3:linear	DCI_C	-0.014265	0.754364	1.000000
3:linear	DCI_I	0.005227	0.636717	1.000000
3:sparse	MCC	0.005308	0.401554	1.000000
3:sparse	DCI_D	-0.091953	0.128167	1.000000

设置	指标	平均差 CDC−Pred	原始p	Holm校正p
3:sparse	DCI_C	-0.093642	0.135340	1.000000
3:sparse	DCI_I	0.005429	0.580668	1.000000
3:dense	MCC	-0.017477	0.346998	1.000000
3:dense	DCI_D	-0.004121	0.832442	1.000000
3:dense	DCI_C	-0.021837	0.451455	1.000000
3:dense	DCI_I	-0.016434	0.178058	1.000000
text	MCC	0.090456	0.156415	1.000000
text	DCI_D	0.034604	0.237385	1.000000
text	DCI_C	0.039366	0.314105	1.000000
text	DCI_I	0.005093	0.817047	1.000000

小样本正态性未验证；文本三次划分共用同一数据源，因此这里只是透明的探索性计算。作者原文显著性无法从已发表均值复算，本章不补造原文p值。

9.6 理论核验与实际耗时

理论脚本的11类检查覆盖：缺秩反例、log-odds左逆、反事实可实现性、单稀疏列结构、固定尺度旋转、尺度收缩、动态规划/穷举、梯度有限差分、DCI手算、混合函数与softmax规范自由度。

本次所用合成完整流程实测约18.23分钟；冻结文本特征提取约155.2秒；9次文本对齐/评价合计约38.0秒。计时受并发、导入与硬件影响，不与作者GPU耗时作严格性能比较。

独立复核覆盖63次模型运行，重新拟合63次训练集评价器；共比较3,636,804个原始数值/汇总项，最大绝对差0。这包括数据混合、测试表征、逐因素预测分数、DCI/MCC及统计汇总，不是3,636,804次独立实验。

9.7 下载与证据范围

- 计算证据包（代码、协议、逐样本结果、检查报告）
- 机器可读摘要 · 全部运行CSV · 验证报告

不公开原始人物简介、完整LM权重、机器路径或凭据。只有实际运行过的数字标为实跑；所有新结果的聚合、绘图、检验由脚本生成，数值复核失败会阻止最终打包。

10｜附录B–C：混合函数、敏感性与尚未证明的扩展

10.1 六个混合函数：逐项转成代码

以下忠实对应附录B（PDF第19页），将下标统一为$0,1,2$。正文有时用1起始，别因此误添一个变量。

二维线性：

$$x = [2z_0, 5z_1, z_0 + z_1, 2z_0 + z_1, -z_0 + 4z_1, 3z_0 - 2z_1].$$

二维非线性稀疏：

$$x = [z_0, 2z_0 + 3z_0^2, 4z_1, 2z_1^2 + z_1^3, 6\sin z_0, -2\cos z_1].$$

二维非线性稠密：

$$x = [z_0 z_1, z_0 + 3z_1, z_0^2 z_1, z_0 z_1^3, 2z_0 + z_1, 2z_0 z_1^2].$$

三维线性：

$$\begin{aligned} x = [&2z_0, 5z_1, 3z_2, z_0 + z_1 + z_2,\\ &2z_0 + z_1 + z_2, -z_0 + 4z_1 - 3z_2, 3z_0 - 2z_1 + 5z_2]. \end{aligned}$$

三维非线性稀疏：

$$\begin{aligned} x = [&z_0, 2z_1, 6z_2, z_0 + 3z_0^2, z_1^2 + 4z_1^3,\\ &z_2 + 5z_2^2, z_0\cos z_0, 6\sin z_1, z_2 \sin z_2]. \end{aligned}$$

三维非线性稠密：

$$\begin{aligned} x = [&z_0 z_1 z_2, z_0 + 3z_1 + 5z_2, z_0^2 z_1 z_2,\\ &z_0 z_1 z_2 \sin z_2, 2z_0 + z_1 z_2, 2z_0 z_1^2 z_2^2]. \end{aligned}$$

输出维度分别为6、6、6、7、9、6；不能为方便网络而静默改成统一维度。脚本检查每个函数的形状和整数算例。

10.2 本地标签生成的明确约定

本次取$z \sim \mathcal{N}(0, I)$。二维按$z_1 < -0.6$、$z_1 > 0.6$和中间区间的z_0正负形成四个组。三维再按$z_2 > 0$把每组分成两组。

这沿用了作者示意中的稀疏分区思想，但具体阈值、三维8组扩展不是原文完整代码。确定性分区也不等于有限权重softmax随机标签；协议如实记录这一理论/实验差别。

10.3 潜维数过多：原文报告

真实$d = 2$，学习维数设3或4：

覆盖约束	学习维数	D（原文报告）	C（原文报告）
放松	3	0.95 ± 0.03	0.81 ± 0.14
放松	4	0.94 ± 0.04	0.76 ± 0.19
保留	3	0.64 ± 0.11	0.81 ± 0.14
保留	4	0.89 ± 0.08	0.57 ± 0.13

直觉：多余坐标可能复制某个真实因素，导致完整度C降低。强迫扰动覆盖不存在的额外真实方向，也可能扭曲解释。

这些是作者附录C数值，本次未重跑这一敏感性系列；±的原始运行数据未取得，不自行推断其置信区间。

10.4 潜维数过少：原文报告

真实$d = 3$但只学2维，作者报告D为0.51 ± 0.20。它支持维数不足会阻碍逐轴解缠，但不意味着所有$d > \hat{d}$问题都具有同一分数或同一失败方式。

真实数据没有因素标签时不能直接计算监督DCI来选维数。作者建议借助多次训练的一致性等无监督信号；一致性高也可能只是重复同一偏差，需要独立验证。

10.5 干预层的选择：原文报告

作者在Llama各层最后token位置提取特征。前9层不呈现相同轴结构，10–30层与最后层的无监督解缠相似度为0.78 ± 0.02，前9层为0.39 ± 0.20。

这不是直接测得“真正伤害性变量的恢复率”。它比较不同层学到的表示，不能把最后层当成已知真实因果标签。

层9也不是所有模型都适用的阈值。模型架构、提示、token位置、行为定义和解释器训练方式都会影响它。

10.6 2-sparse及p-sparse扩展

若每次只改变一个**块**里的p个概念，但块内缺少进一步信息，最多可能识别到块内可逆混合：

$$A = P \ \mathrm{blockdiag}(A_1, \ldots, A_t),$$

而不是每个标量轴的尺度/置换。若不同稀疏块重叠，交集可能提供更细的识别线索。

作者构造$d = 3$的重叠2-sparse分组，报告5次运行D为0.95 ± 0.02、C为0.98 ± 0.01、I为1.0 ± 0.0。

边界： 作者明确把一般p-sparse理论留给未来工作。这些额外实验不是已经完成的普遍扩展证明，本次也没有把它们标成重新计算。

10.7 如何设计下一轮有意义的敏感性实验

可以预先登记一个因素一次变化：维数、候选数、正则权重、归一化、组阈值或锚点数。保持数据和种子配对，报告所有结果，并用新的保留测试集确认结论。

本次没有在看过测试结果后自动启动搜索。这样避免把“为了找到好看的分数”包装成公平复现。

11 | 核对清单：数学缺口、复现边界与伦理

> **本章是非正式技术核对，不是作者正式勘误。** 对每个问题注明其范围；不把一个环节的反例夸大成对所有潜在补全定理的否定。

11.1 证明链核对

环节	可确认部分	还需要什么
交叉熵最优→真实概率	正确的总体KL分解	可实现、优化到总体最优；通常只几乎处处
相同softmax→相同logits	只能确定到共同输入相关项	使用参考log-odds精确消去
类别多→可逆矩阵	不能仅由$m > d$推出	权重差满秩、真实支撑满维、学习维数相同
换位成功→观测纯配对	原定义不自动保证	反事实可实现性或支撑闭包
真实纯配对→单稀疏列	同一配对上可严格推出(5)	配对确实选对、幅度非零
构造另一点→矛盾	代数抵消可写出	该点确实存在于相应组；学习坐标必要性有依据
所有轴→尺度置换	可逆、逐列单稀疏时成立	不能省略非零和覆盖
匹配数更多→平方总损失更低	一般不成立	控制非零残差幅度/权重或改变目标
残差变小→识别更好	存在共同缩放退化	尺度固定、非零幅度、有界性等
差分约束→原点识别	平移始终抵消	中心化或承认平移不确定性

精确反例与计算细节见05–06章及`results/theory/checks.json`。有限数值检查能发现不成立的中间推理，但不能证明任意分布下的全局算法识别定理。

11.2 论文自身符号/表述的小问题

- 正文先用k表示因素数，定义中改用d；本手册统一为d。
- y既指输出序列，又在公式(3)作行为类别索引；本手册损失统一用c。
- “span等于d”应理解为span维数等于d。
- $m > d$时堆叠矩阵一般为长方形，不可直接说普通逆存在。
- 附录A公式(5)正确比例是c_s/b_r，邻近文字把比例倒过来。
- “旋转但解缠”的措辞应区分信息未丢与坐标对齐；I高不意味着D高。

这些修订不会被静默写回原始来源，图像与来源清单保留原貌。

11.3 代码与数据核对

项目	本次状态
正式PDF	已下载、记录SHA256、29页
官方补充代码	未取得；OpenReview验证阻挡，不绕过验证
独立实现	已运行，全部约定与源码可下载
合成原始因素/输入/划分	保存并允许复算
模型检查点/低维表示/评价器预测	保存；重复执行补存证据不改训练协议
作者原始测试预测	未取得，不伪造
大型LLM与SAE实验	未执行，仅说明作者设置与后续需求
原始人物简介	仅合法获取供本地计算，不复制到公开网站

11.4 统计核对

作者用5个测试分块作独立t检验，不等于5次训练。原图SAE阴影、附录维数实验的重复与本次3种子SD也不是同一随机来源。

本次每个设置报告所有值，探索性检验声明28项校正家族。小样本、共享数据与未验证正态性都限制显著性解读。没有重现作者p值，不给作者表格补造置信区间。

11.5 NeurIPS Checklist怎么读

PDF第23–29页包含16项检查表。作者自报理论/证明、实验可复现、代码数据、设置、显著性、算力、伦理、既有资产许可等为Yes；社会影响、保障措施、众包、IRB、核心LLM使用等多项为NA。

这是**作者披露**，不等于外部审计已经完成。本次能核实的来源与计算单独列出，不能从“Yes”推断本次已获得补充代码或所有定理没有缺口。

检查主题	阅读时追问
1–3 结论/局限/理论	假设是否足以支持陈述强度?
4–8 复现/开放/设置/统计/算力	能否拿到代码、精确配置、原始结果与资源?

检查主题	阅读时追问
9–12 伦理/影响/保障/许可	公开数据是否含个人信息，许可是否一致?
13–16 新资产/人类参与/IRB/LLM	是否新增资产，有无人类研究或核心LLM协助需披露?

11.6 许可与隐私

上一篇论文的CC BY 4.0不能自动套到这一篇。本次未独立确认正式论文再发布许可，公开网站链接到原PDF，不镜像整份论文；原图节选附作者、页码和对应评论，版权归原作者。

作者附录写BiasBios为Apache-2.0，本次使用的公开镜像卡写MIT。两者不自动等价，记录具体镜像与提交，不混用许可声明。公开包不包含人物原文。

网页无第三方追踪，不调用模型API，阅读记录仅浏览器本地保存。发布时仅白名单文件，不上传缓存、模型权重、凭据、其他项目或本机路径。

11.7 应用伦理

收入例子的性别因素来自有限二元标签，不能代表所有性别；模拟收入等级不等于个人真实收入，不应拿来给真人作高风险决定。

拒答概念用于理解安全行为，不应把“发现方向”误作“移除安全机制”的默认用途。轴语义需独立验证，错误解释本身也可能造成偏见或过度信任。

12 | 和上一篇接起来：建立统一但不混淆的理论框架

12.1 两篇都在解决表征的不唯一性

同一观测和预测任务，可能允许许多等价的潜在坐标。研究不是只问“能否拟合”，还要问“什么信息能把等价类缩小到有意义的程度”。

上一篇：Learning Interpretable Concepts: Unifying Causal Representation Learning and Foundation Models（arXiv:2402.09236v2）。本篇：CDC（NeurIPS 2025）。

问题	上一篇	本篇
核心观测信号	基准与概念条件环境	输入激活与行为分组
概念形式	线性测量/概念条件筛选等	高层中介坐标及其稀疏区分作用
关键工具	密度比、充分统计量、环境变化	log-odds、仿射类、组间稀疏差分
主要归纳偏置	筛选/噪声/生成结构条件	logit线性与每轴可单独区分某组对
“干预”边界	条件筛选不一般等于do	潜在换位不自动等于可实现文本干预
因果图恢复	不能自动等同	同样不能自动等同

不能把上一篇的密度比定理直接当成本篇的证明，也不能把本篇的CDC坐标理解成上一篇任意向量$a^\top z$而不检查定义差异。

12.2 一个通用的五层分析框架

1. **观测层：** 真正拿到哪些变量？数据、标签如何生成？
2. **结构层：** 哪些关系是假设，哪些是已测量的事实？
3. **识别层：** 有无限数据、理想优化时，仍有哪些等价变换？
4. **估计层：** 有限样本、神经网络、候选采样、超参数如何影响结果？
5. **解释层：** 坐标语义如何独立验证，能否支持实际干预结论？

许多误读来自跨层跳跃：例如用某次训练二维图很整齐，直接宣布第3层的普遍可识别性成立；或由第3层的条件定理，推断第5层的真实因果语义已经验证。

12.3 CRL和因果发现不是同一任务

因果发现通常问变量之间的因果结构或DAG；本篇先问解释变量本身如何从神经网络激活中找到。

哪怕找到了逐轴概念，仍未确定概念间所有因果箭头、混杂、方向与干预分布。因此它不能直接替代你之前关注的连续优化因果发现方法。

后续可以研究“先学可识别概念，再发现结构”，但需要分析两个阶段的误差和附加假设，不能直接把一篇的结论当成另一篇的输入保证。

12.4 与相关方法的差异

- **线性探针：** 给定概念标签，检验激活是否含有该概念信息；高可预测性不自动证明模型实际使用它。
- **CAA/对比提示：** 用人为配对提示定位方向；概念被监督地预先指定。
- **DII/因果抽象：** 使用已知高层模型或干预关系学习对齐；监督结构比本篇更明确。
- **SAE：** 寻找稀疏激活字典，通常不专门对准一个行为任务；变化稀疏和激活稀疏不同。
- **本篇CDC：** 依靠行为分组和稀疏变化偏置发现相关坐标；不需要真实概念标签训练，但需要核查分组、秩、配对与目标。

12.5 对研究选题的启示，不替你预选结论

可能值得进一步验证的方向：

1. 给出明确秩与支撑条件，严格补全仿射识别命题。
2. 为未知配对建立可证明的选择条件，而非只靠匹配数计数。
3. 设计尺度不变、对候选数鲁棒的稀疏变化目标。
4. 研究真实行为聚类误差和拒答概率代理的影响。
5. 用预注册干预检验而不只是可视化确认概念语义。

这些是由精读提出的研究问题，不是本次已经完成的新论文贡献。要选择其中之一，应先查相邻文献和最新进展，再明确最小可检验命题。

13 | 学习、自测和复现实操

13.1 一周学习路线

天	任务	当日可检验产出
1	先修、01	不看笔记区分$x, g, z, \hat{z}, c$
2	02–03	准确写出必要/充分的量词及两个损失
3	04、07	手算候选残差与一个DCI矩阵
4	05	推导参考log-odds与左逆，解释为什么类别多不等于满秩
5	06、11	复述稀疏列引理，列出未知配对论证的额外条件
6	08–10	解释每张原图、区分作者数据与本地实跑
7	12、计算证据包	重算至少一组测试指标，并形成一页批判性总结

13.2 四个交互实验

打开交互实验室。全部在浏览器本地计算，不训练大型模型，也不冒充新增作者实验。

1. **Softmax：** 修改logits和公共偏移，观察概率不变性与log-odds。
2. **稀疏变化/旋转：** 旋转四点，观察零项计数与总平方损失的差别。
3. **尺度退化：** 缩放表示和扰动，预测不变但对比损失下降。
4. **DCI：** 修改重要性矩阵，比较逐行专一性与逐列完整度。

13.3 代码入口与运行顺序

从计算证据包解压后，在Python 3.11环境安装 `experiments/requirements.txt` 与官方CPU版PyTorch 2.6.0。实际精确依赖版本另见 `environment_freeze.txt` 。

```
python experiments/theory_checks.py
python experiments/run_synthetic.py --n 20000 --epochs 50 --seeds 11,23,37 --output results/synthetic_confirmed
python experiments/prepare_text.py --per-cell 200 --max-length 96 --batch-size 16 --cache ./model-cache
python experiments/run_text.py --output results/text_confirmed
python experiments/verify_results.py
python experiments/summarize.py
```

首次文本运行需下载公开模型与Parquet数据；不需要模型API密钥。没有网络时仍可直接重算已保存的指标和查看全部表格。数据版本固定，来源许可与隐私限制见11章。

若只是学习，先运行理论核验和指标重算，不必再次训练所有模型。不同硬件/库可能导致浮点差异，固定种子不保证跨环境逐位一致。

13.4 四道进阶练习

题1： 为什么I很高但D很低不矛盾？

题2： 推导$v = (3, 4)$在两个单坐标方向上的最优平方残差。

题3： 已知所有列单稀疏，为何还要A可逆才能得到置换？

题4： 如何设计实验区分候选数不足和目标本身偏好旋转这两种原因？

▼ **参考答案**

1. 旋转可保留全部信息，但每个轴混合多个因素；评价器可联合恢复，轴本身却不专一。
2. 轴1取幅度3，残差16；轴2取幅度4，残差9。
3. 不可逆时多列可落在同一行，丢失独立方向；例如$\begin{pmatrix} 1 & 2 \\ 0 & 0 \end{pmatrix}$。
4. 在已知真实坐标的小规模离散数据上精确穷举全部配对与轴，比较不同旋转的全候选目标；再固定目标与尺度改变候选预算，保持数据/种子配对。新实验应另行预登记，不混进原来的测试结果。

13.5 完整原规模复现还缺什么

- 作者补充代码、精确配置、原始数据筛选和划分、真实行为概率定义。
- Llama/Qwen模型及LlamaScope SAE的具体版本、使用授权、GPU环境。
- 足够内存/显存、运行预算和按种子重复的计算时间。
- 原始逐样本预测或作者统计中间量，用来核验原文显著性。

本次没有自动租用云GPU，也未借缩小实验宣称这些项目已经完成。拿到资源后应另建执行记录，保留当前证据，不覆盖失败结果。

13.6 一页总结模板

论文要解释的行为是什么？c如何得到？
真实/假设概念与学习表征分别是什么？
哪条假设用于从预测等价缩到仿射等价？
哪条信息用于从仿射缩到尺度/置换？
未知配对与反事实可实现性在哪里进入？
哪些实验有概念真值，哪些只有案例解释？
我的计算结果和作者报告分别支持到哪一步？
仍无法验证的结论与所需资源是什么？

能完整回答这些问题，比背下“提出新目标并达到SOTA”更接近真正读懂这篇论文。

词典 | 中英术语随查：直觉、定义、例子与用途

共82个教学词条，通用基础与CDC专用概念分组。不要从头背；先读基础补课。原文术语和本次补充条件会区分。

概率基础

随机变量 • random variable

直觉： 还没抽样时，用一个符号代表可能出现的数值；抽样后，它才落成一个具体结果。

定义： 随机变量是把随机结果映射成数的函数。Z通常表示随机变量，z表示一次实现；多个数一起记录就是随机向量。

例子： 随机抽一张图片，Z_1记录物体的颜色强度。抽之前Z_1不确定，抽之后可能得到$z_1 = 0.7$。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** “随机”不表示毫无规律；规律由概率分布描述。

概率分布 • probability distribution

直觉： 描述各种结果各有多容易出现，而不是一张具体图片或一个数。

定义： 离散分布给出$P(Z = z)$；连续分布通常用密度$p(z)$描述区域概率。分布本身是给集合赋概率的规则。

例子： 抛硬币的分布可以是正反各一半；扔100次得到的那串结果只是这个分布产生的一组样本。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 两个环境样本数量不同，不等于它们的生成分布一定不同；一次抽样也无法精确

> 揭示总体分布。

概率密度 • probability density

直觉： 连续数值轴上“概率有多集中”的高度。概率是曲线下的面积，不是曲线高度。

定义： 若Z有密度p，则$P(a \le Z \le b) = \int_a^b p(z)\,dz$，且$p \ge 0$、$\int p = 1$。

例子： $Z \sim U[0, 0.2]$时，区间内密度为5，而整个区间的概率为$5 \times 0.2 = 1$。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 连续分布在单点上的概率可以为0，但该点的密度不必为0，也不必小于1。

期望 • expectation

直觉： 按照每个结果出现的可能性进行加权平均。

定义： 离散时$E[Z] = \sum_z z P(Z = z)$；连续时$E[Z] = \int z p(z)\,dz$，前提是相应期望存在。

例子： 公平骰子的期望为$(1+2+3+4+5+6)/6 = 3.5$。一次投掷不可能出现3.5，但平均位置可以是3.5。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 总体期望不等于一次样本的值；样本均值也不保证恰好等于总体期望。

方差与标准差 • variance / standard deviation

直觉： 描述数值围绕均值散得多开。标准差与原变量同单位，方差使用平方单位。

定义： $\mathrm{Var}(Z) = E[(Z - EZ)^2]$，标准差为$\sqrt{\mathrm{Var}(Z)}$。

例子： 等概率取0和2：均值1，方差$[(0-1)^2+(2-1)^2]/2=1$。等概率取−1和3，均值仍为1，方差变成4。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 论文写N(μ,σ²)时第二个参数是方差；有些软件接口却要求传标准差。

协方差 • covariance

直觉： 检查两个数是否倾向一起偏大或反向变化，主要衡量线性共变。

定义： $\mathrm{Cov}(U,V)=E[(U-EU)(V-EV)]$。非零方差时，相关系数是协方差除以两个标准差之积。

例子： 若$U\sim U[-1,1]$、$V=U^2$，由对称性可得协方差为0，但V完全由U决定。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 不相关通常不等于独立。对联合高斯这一特殊模型，零交叉协方差才可推出相应独立性。

统计独立 • statistical independence

直觉： 知道其中一个随机量的结果，不会改变另一个随机量的分布。

定义： 对任意合适集合A、B，$P(U\in A,V\in B)=P(U\in A)P(V\in B)$。有联合密度时对应$p(u,v)=p(u)p(v)$。

例子： 两枚独立硬币中，看到第一枚是正面，并不会改变第二枚正面的概率。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 这是随机变量的性质，不是向量的线性独立或正交。三个“独立/正交”概念不能互换。

条件概率与条件分布 • conditional distribution

直觉： 得到额外信息后，重新计算可能性。可以理解为只在满足信息的样本中比较比例。

定义： 当$P(B) > 0$时，$P(A \mid B) = P(A \cap B)/P(B)$。连续条件常通过联合密度定义$p(z \mid y) = p(z, y)/p_Y(y)$。

例子： 100个物体中20个红色，其中8个是圆的。条件在“红色”后，圆形概率是8/20，不是8/100。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 连续条件Y=y不能机械地用两个零概率相除；应使用条件密度或适当的条件分布定义。

贝叶斯更新 • Bayesian update

直觉： 用新证据给原来的可能性重新加权，再把总量归一化。

定义： $p(z \mid y) = p(z)p(y \mid z)/p(y)$。先验$p(z)$是看证据前的分布；似然$p(y \mid z)$衡量给定z时证据多符合；后验是更新后的分布。

例子： 两种情况先验各1/2，证据似然分别0.8和0.2，未归一化权重为0.4和0.1；后验为0.8和0.2。

在论文中的用途： 理解条件标签概率、类别后验与交叉熵的总体最优性。不要把它误读为本文又在进行高斯概念筛选。

> **别混淆：** 似然作为z的函数，一般不是关于z已经归一化的概率分布。

归一化 • normalization

直觉： 把相对权重缩放成总和或总积分为1的概率。

定义： 若$w(z) \geq 0$且$0 < N = \int w(z)\, dz < \infty$，则$p(z) = w(z)/N$是密度，N叫归一化常数。

例子： 权重2、3、5的总和为10，归一化概率为0.2、0.3、0.5。只有比例信息，也能得到概率。

在论文中的用途： softmax分母一般依赖z，不能把它当成常数偏移。另一个问题是表征尺度归一化；它用于避免平方对比损失通过整体缩小而降低。

> **别混淆：** 向量除以自身长度也叫“归一化”，但它与概率归一化不是同一操作。

高斯分布 • Gaussian distribution

直觉： 由中心位置和扩散程度控制的钟形分布。

定义： $\mathcal{N}(\mu, \sigma^2)$的密度为$\frac{1}{\sqrt{2\pi\sigma^2}} \exp[-(z-\mu)^2/(2\sigma^2)]$，其中$\sigma > 0$。

例子： 标准高斯是$\mathcal{N}(0, 1)$。均值从0改成2会平移曲线；减小方差会使曲线更窄、更高。

在论文中的用途： 合成实验的因子从高斯采样，VAE也使用高斯近似；这与上一篇“高斯筛选噪声”是不同设定。

> **别混淆：** 多维高斯还要给协方差矩阵。只有对角协方差并满足联合高斯模型时，坐标才相互独立。

密度比 • density ratio

直觉： 比较同一位置在两个环境中相对有多常见。

定义： 在分母正的区域，密度比为$p^e(z)/p^0(z)$，对数密度比为$\log p^e(z) - \log p^0(z)$。

例子： 若$p^e(z) = p^0(z)w(z)/N_e$，则比值为$w(z)/N_e$。复杂的基准密度被约掉了。

在论文中的用途： 这是上一篇论文的核心工具。本篇主要使用行为类别的softmax与log-odds，不直接复用高斯筛选环境的密度比证明。

> **别混淆：** 分母为0处不能直接相除。密度比大于1表示相对密度增加，不代表该点的概率超过1。

支撑集 • support

直觉： 数据分布实际上能到达的区域，而不是符号上允许写出的整个空间。

定义： 严格地说，支撑中的点的任意邻域都有正概率。对常见连续密度，可以从密度为正的区域及其边界来理解。

例子： 均匀分布U[0,1]不会产生2。只在[0,1]上观察数据，不能直接知道某个函数在2处的值。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 有限样本没有碰到某处，不等于该处分布概率严格为0。

线性代数

向量 • vector

直觉： 把一组有顺序的数打包；也可在固定坐标系中表示一个方向或位置。

定义： 列向量$z = (z_1, z_2, z_3)^\top \in \mathbb{R}^3$有三个分量。行列方向影响矩阵乘法的维度。

例子： z=(2,3,4)可以记录三个潜因素。它有三个数，不意味着每个数已经有“颜色、大小、形状”的语义。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 坐标取决于表示方式。不同潜坐标中的两个向量，不能不做坐标对齐就直接比较。

内积 • inner product

直觉： 一个向量对另一个向量做加权求和；也能衡量方向对齐程度。

定义： 欧氏内积$a^\top z = \sum_i a_i z_i$，结果是一个标量。它等于$\|a\|\|z\|\cos\theta$。

例子： a=(1,2)、z=(3,4)时，$a^\top z = 1\times 3 + 2\times 4 = 11$。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 内积不是逐元素乘积向量；内积把所有分量相乘后还要相加。

矩阵 • matrix

直觉： 把多个线性测量排成一张表，一次读出多个数值。

定义： $A \in \mathbb{R}^{k\times d}$乘$d$维列向量，得到$k$维向量；第i个结果是A第i行与z的内积。

例子： $A = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$、$z = (3,4)^\top$，则$Az = (3,8)^\top$。

在论文中的用途： W是行为分类的权重，A是定理1中待消除的仿射混合，D或P表示尺度/置换；这些矩阵不是因果邻接矩阵。

> **别混淆：** 先查维度再计算。k×d矩阵不能直接右乘k维向量，除非k恰等于d。

转置 • transpose

直觉： 把矩阵的行和列互换。

定义： $(A^\top)_{ij} = A_{ji}$。列向量a转置后为行向量$a^\top$，这样$a^\top z$才是通常的标量内积。

例子： $\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}^\top = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix}$。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 转置通常不是求逆。只有正交方阵等特殊情形，转置才等于逆矩阵。

线性映射 • linear map

直觉： 输入的加法和缩放可以直接穿过这个映射。

定义： $L(\alpha u + \beta v) = \alpha L(u) + \beta L(v)$。有限维空间中可用矩阵表示，且$L(0) = 0$。

例子： L(z)=2z是线性的；L(z)=2z+1是仿射而非线性；L(z)=z²通常是非线性的。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** “线性”不是“容易”“看上去像直线”的同义词；必须看映射对加法和缩放是否满足定义。

线性独立 • linear independence

直觉： 这组向量中没有一个方向能完全由其他方向拼出来。

定义： 若$\sum_i c_i a_i = 0$只能推出所有$c_i = 0$，则这些向量线性独立。

例子： (1,0)与(1,1)独立但不正交；(1,0)与(2,0)不独立，因为第二个是第一个的两倍。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 线性独立不要求概念求值在统计上独立，也不要求向量互相垂直。

正交 • orthogonality

直觉： 在指定内积下方向互相垂直，投影为零。

定义： 欧氏空间中，$u^\top v = 0$表示正交。两个子空间正交，是指各自任意向量的内积都为0。

例子： (1,0)与(0,1)正交；(1,0)与(1,1)不正交，但它们仍线性独立。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 一般可逆坐标变换不保持欧氏正交。几何正交不自动等于语义互不影响或统计独立。

张成空间 • span / column space / row space

直觉： 用一组向量作任意线性组合，能到达的全部方向。

定义： $\mathrm{span}(a_1, \ldots, a_n) = \{\sum_i c_i a_i\}$。矩阵的列空间由列向量张成，行空间由行向量张成。

例子： (1,0,0)与(0,1,0)张成三维中的一个平面；再加(1,1,0)不会增加新方向。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 行空间与列空间可以位于不同维度的环境空间；不能只因秩相同就把二者当成同一个集合。

矩阵的秩 • rank

直觉： 矩阵中真正独立的信息方向有多少个。

定义： 秩等于列空间维度，也等于行空间维度。$m \times n$矩阵满列秩指秩为n，满行秩指秩为m。

例子： $\begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix}$ 有3行但只有2列，秩为2；它满列秩，不满行秩。

在论文中的用途： 定理1需要类别权重差具有足够秩；类别数m>d只是必要的数量条件，不自动保证满秩。定理2还需要扰动覆盖全部方向。

> **别混淆：** 矩阵大、样本多或行列数多，并不自动意味着满秩；重复信息不会提高秩。

零空间 • null space / kernel

直觉： 输入沿这些方向变化，矩阵测量完全看不见。

定义： $\ker A = \{v : Av = 0\}$。若$Az = b$，则对任意$v \in \ker A$，都有$A(z + v) = b$。

例子： A=(1,0)只读第一坐标；所有(0,t)都在零空间中，改变第二坐标不改变该测量。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 零空间不是只有零向量的空间；通常包含很多非零向量。

左零空间 • left null space

直觉： 给矩阵的各行配权重，让加权结果完全抵消；等价于垂直于全部列向量。

定义： $\{v : v^\top M = 0\} = \ker M^\top$。若M有m行、秩为r，左零空间维度为m−r。

例子： 对三行两列的$M = [(1,0); (0,1); (1,1)]$，$v = (-1,-1,1)^\top$满足$v^\top M = 0$。

在论文中的用途： 通用线性代数背景；本篇不使用上一篇论文的M、B左零空间主证明。这里更关键的是log-odds权重差的秩。

> **别混淆：** v和w在证明中承担不同角色；左零向量也只在乘非零尺度的意义下可能唯一。

逆映射与可逆 • inverse

直觉： 可以从输出唯一地找回输入。

定义： 若f在其像集上单射，就有该像集上的逆f^{-1}。方阵T可逆时，$T^{-1}T = TT^{-1} = I$。

例子： f(z)=2z可由x/2恢复；f(z)=z²若定义在整个实数轴上，则无法区分z和−z。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 单射可微不保证逆映射处处可微；f(t)=t³的逆在0处不可微。

伪逆 • pseudoinverse

直觉： 普通逆不存在时，用一个有明确最小二乘/最小范数含义的替代算子。

定义： 满行秩时$A^+ = A^\top (AA^\top)^{-1}$，且$AA^+ = I$。在约束可解时，$A^+b$给出$A\eta = b$的最小欧氏范数解。

例子： A=(1,1)、b=2时，所有解满足$\eta_1+\eta_2=2$；伪逆给出(1,1)，比(0,2)的长度更短。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 一般A^+A不是单位阵，而是投影矩阵。不能把伪逆当成对所有输入都无损恢复的普通逆。

仿射空间 • affine space

直觉： 把过原点的线性空间整体平移；方向不变，位置可以变。

定义： 若$Az_0=b$有解，则$\{z : Az = b\} = z_0 + \ker A$。仿射映射的形式是Tz+c，允许有偏移c。

例子： 二维里y=0是线性子空间，y=2是平移后的仿射直线；它们方向相同、位置不同。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 仿射空间不一定经过原点；因此它通常不满足向量相加后还留在集合中。

维度与余维 • dimension / codimension

直觉： 维度数还可以自由变化的独立方向；余维数相对于整个空间少了几个自由方向。

定义： 在d维空间中，满行秩k个线性约束Az=b的非空解集维度为d−k，余维为k。

例子： 三维里一个平面有2个自由度、余维1；一条直线有1个自由度、余维2。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 观测坐标个数d_x、潜空间维度d_z与目标概念数n，是三个不同的数字。

投影 • projection

直觉： 保留某个子空间中的分量，舍弃与它正交的分量。

定义： 欧氏正交投影矩阵P满足$P^2 = P$且$P^\top = P$。A^+A投影到A的行空间。

例子： 把(3,4)投影到横轴得到(3,0)；第二分量被舍去，通常不能再恢复。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 投影一般不可逆。改写几何约束为投影形式，也不自动保持噪声独立同方差。

范数与最小范数 • norm / Euclidean norm

直觉： 用一个数衡量向量有多大；先指定测量大小的规则，才谈得上最小扰动。

定义： 欧氏范数$\|v\|_2 = \sqrt{\sum_i v_i^2}$；$\ell_1$范数$\|v\|_1 = \sum_i |v_i|$。

例子： (3,4)的欧氏长度是5，ℓ_1长度是7。同一个约束下，不同度量可能选出不同的最小编辑。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 小范数不自动意味着语义副作用小；网络输出对不同方向的敏感性可能不同。

正定矩阵与特征值 • positive definite / eigenvalue

直觉： 协方差对任何方向都不可能给出负方差；正定进一步要求每个非零方向都有严格正的方差。

定义： 对称矩阵G正定指$v^\top Gv > 0$对所有非零v成立；半正定允许等于0。特征向量满足$Gv = \lambda v$，λ为特征值。

例子： $\begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix}$的特征值是1+ρ和1−ρ；当|ρ|<1时都为正，因此矩阵正定。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 矩阵所有元素为正并不等于正定；正定看的是所有方向的二次型，或对称矩阵的特征值。

微积分与证明

导数与偏导数 • derivative / partial derivative

直觉： 输入轻微改变时，输出以多快的速度变化。

定义： 一元导数$f'(z) = \lim_{h\to 0}[f(z+h) - f(z)]/h$；偏导数则只改变一个坐标、固定其他坐标。

例子： $f(z) = z^2$时$f'(z) = 2z$；在z=3附近，输入增加0.01，输出约增加0.06。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 导数描述局部变化，不等于整个函数值；导数为0也不自动意味着全局最小。

梯度 • gradient

直觉： 把一个标量函数对所有输入坐标的偏导排成向量。

定义： $\nabla L = (\partial L/\partial z_1, \ldots, \partial L/\partial z_d)^\top$，在欧氏度量下指向局部最快上升方向。

例子： $L(z_1, z_2) = z_1^2 + 2z_2^2$时，$\nabla L = (2z_1, 4z_2)^\top$；在(1,1)处为(2,4)。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 梯度与Jacobian的形状取决于函数输出维度。不要把向量输出的所有导数都叫一个普通梯度向量。

雅可比矩阵 • Jacobian

直觉： 向量函数在一个点附近如何拉伸、旋转和混合小扰动的局部说明书。

定义： 对$f : \mathbb{R}^d \to \mathbb{R}^k$，$Df$是k×d矩阵，元素为$\partial f_i/\partial z_j$，且$f(z+\delta) \approx f(z) + Df(z)\delta$。

例子： $f(z_1, z_2) = (z_1, z_2 + z_1^2)$时，$Df = \begin{bmatrix} 1 & 0 \\ 2z_1 & 1 \end{bmatrix}$。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 只有方阵才有普通行列式。高维嵌入的体积因子不能直接写成非方阵的det。

链式法则 • chain rule

直觉： 一个变化先经过内层函数、再经过外层函数时，将两段局部变化组合起来。

定义： 一元时$(g \circ f)'(z) = g'(f(z))f'(z)$；向量时$D(g \circ f)(z) = Dg(f(z))Df(z)$。

例子： y=(2z+1)²时，导数是$2(2z+1) \times 2 = 4(2z+1)$，最后的2来自内层函数。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 矩阵乘法的顺序不能随便调换；先检查各段输入、输出维度。

最小值与argmin • minimum / argmin

直觉： 最小值是最低的函数高度；argmin是达到这个高度的输入位置，可能有很多个。

定义： $\min_z F(z)$是数，$\operatorname{argmin}_z F(z)$是集合。本论文极小集写作argmin，使用的是全局最小位置。

例子： $F(z_1, z_2) = (z_1 - 1)^2$的最小值为0，argmin是整条直线$\{(1, t) : t \in \mathbb{R}\}$。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 局部极小与全局最小不同。梯度为0的点也可能是极大点或鞍点。

多项式 • polynomial

直觉： 由变量的非负整数次幂相加组成的函数；次数记录最高的总幂次。

定义： $2z_1^2 + 3z_1z_2 + z_2 + 1$是二次多项式；$z_1z_2$是交叉项，$z_1^2z_2$总次数为3。

例子： 若$u = z_1 + z_2$，则$u^2 = z_1^2 + 2z_1z_2 + z_2^2$；平方会暴露两个坐标的混合。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 比较多项式系数需要足够区域上的函数恒等；有限训练点拟合相等不足以证明这些系数恒等。

几乎处处 • almost everywhere

直觉： 允许一个相对于指定体积测度可以忽略的例外集合；不是说没有例外。

定义： 关于Lebesgue测度，有限点、平面中的曲线等常见低维集合可以测度为零。几乎处处相等意味着不相等的集合测度为零。

例子： 在实数轴上，改变一个点的函数值不影响常见积分，却会使两函数不再处处相等。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** Lebesgue零测集不一定对任意概率分布都概率为零；一个点质量分布可以把全部概率放在一个点上。

连续与可微 • continuity / differentiability

直觉： 连续表示输入足够接近时输出也接近；可微进一步要求局部能用线性变化近似。

定义： 可微蕴含连续，反过来通常不成立。连续性还能把稠密集合上的函数等式延拓到极限点。

例子： $|z|$在0处连续但不可微；z^3单射且可微，其逆$x^{1/3}$在0处却不可微。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 单射、连续、可微、光滑逆是不同条件，不能看到其中一个就默认其他全部成立。

模型与识别

潜变量与观测变量 • latent variable / observed variable

直觉： 观测变量是直接记录的数据；潜变量是模型用来解释数据、通常看不到的内部因素。

定义： x是输入文本，g(x)是可提取的模型激活，z是未直接观察的高层中介因素。本文不需要把所有文本都放进一个已知可逆的$X = f(Z)$生成模型。

例子： 拍摄物体时，图片像素是观测；颜色、光照、相机角度等可以是潜因素。

在论文中的用途： 先把x、g(x)、z、$\hat{z}$和c分开；它们分别是文本、激活、真实概念、学习特征和行为标签。

> **别混淆：** 给潜变量起了“颜色”这个名字，不代表已证明它真的对应颜色或具有因果意义。

表征 • representation

直觉： 把复杂对象变成便于计算的一组特征，相当于给对象换一种记账方式。

定义： 表征可以是图片、文本对应的向量；学习表征是从数据中学习这种转换。一个可用表征不一定唯一。

例子： 同一温度可以用摄氏度或华氏度记录；同一图片也可以用多套可相互换算的特征表示。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 能分类、能重建、可解释、可识别、具有因果意义是不同评价目标。

中介概念 • mediating concept

直觉： 解释模型为什么表现不同的高层属性，例如职业和性别；不是给单个神经元直接贴一个名字。

定义： 本篇设真实高层概念为z，行为类别为c；z对行为保留足够信息，形式上$c \perp x \mid z$。学习目标是$\hat{z} = \tau(g(x))$。

例子： 同样询问收入，职业可能决定高低收入区间，性别在中等收入职业中影响模型的预测。概念是解释这种行为规律的属性，而不是实际收入的证明。

在论文中的用途： 本文的中介坐标z不同于上一篇任意线性测量$a^{\top}z$的概念定义。两篇论文的问题和假设需要分开。

> **别混淆：** “因果区分概念”是本文的特定定义，不意味着已经恢复现实世界的因果图或全部语言模型概念。

行为组 • behavior group

直觉： 先根据模型行为把输入分组，再问哪些内部因素解释组间差异。

定义： $C_k = \{x : c(x) = k\}$，表示属于行为类别k的输入集合。k、l是组编号，不是已知概念编号。

例子： 高拒答概率、中拒答概率、低拒答概率可以形成三个行为组；收入预测例子形成四个组。

在论文中的用途： 训练可以使用行为组标签c，但不使用真实概念z的标签。因此“无监督”主要指不需要概念标注，不是完全没有标签。

> **别混淆：** 行为组不是已知的纯反事实配对；两个不同组样本可能同时在许多概念上不同。

可识别性 • identifiability

直觉： 即使知道了所有总体数据规律，还有没有两种本质不同的解释都同样说得通？

定义： 若产生相同可观测分布的所有合法模型，只能相差预先允许的等价变换，就称目标在该等价意义下可识别。

例子： 若s和2s+3只差单位和零点，可以允许；若s与s加上另一个概念的混合也无法区分，逐原子识别就更弱。

在论文中的用途： 目标先从任意表征缩小到仿射混合，再进一步缩小A到逐坐标尺度和置换；原证明的秩、可实现性、尺度与全局最优条件需核查。

> **别混淆：** 可识别性是“原则上信息够不够”，不是“训练算法是否找得到”“有限样本误差有多小”。

等价类 • equivalence class / permutation

直觉： 把只差允许记号或坐标变换的表示视为同一种解释。

定义： 逐原子关系常写成$\tilde{s}_{\pi(i)} = \lambda_i s_i + c_i$，其中π是重排、λ非零、c是零点偏移。

例子： 将“颜色、大小”两列交换名称，或把米换成厘米，并没有损失同样的测量内容。

在论文中的用途： A=DP意味着列不再混合不同概念；若表征未中心化，平移b在差分目标中仍会抵消，不能悄悄认定b已被识别。

> **别混淆：** 允许什么等价变换必须先定义。不能把所有不同模型都随意说成“只是换坐标”。

总体与有限样本 • population / finite sample

直觉： 总体是完整的数据生成规律；样本是这条规律随机产生的有限记录。

定义： 总体风险是对真实分布取期望的损失；经验风险是有限样本上的平均损失。二者一般不完全一样。

例子： 公平硬币的总体正面概率是1/2，但10次投掷可能出现7次正面；这不说明总体概率变成0.7。

在论文中的用途： 总体交叉熵最优不等于有限数据训练最优；五个测试子集也不等于五次独立训练。

> **别混淆：** “无限数据仍有歧义”和“有限数据估不准”是两个不同困难，不能混为一谈。

充分统计量 • sufficient statistic

直觉： 统计量是数据的函数；充分统计量在指定统计模型下保留了关于参数所需的信息。

定义： 一个严格刻画是：给定该统计量后，数据的条件分布不再依赖待估参数。它始终相对于某个模型和参数定义。

例子： 高斯对数密度可写成$\eta_1 z + \eta_2 z^2 - c$，因此z和z²是自然出现的指数族统计量。

在论文中的用途： 可选背景。本篇仿射识别路线来自logit线性和权重差秩，不应直接套用上一篇高斯充分统计量的证明。

> **别混淆：** 这里不能只凭“压缩后好用”就宣称充分性，也不能忽略模型中未知基准分布等

> 设定。

指数族 • exponential family

直觉： 把分布写成“公共基底 × 指数中的参数与统计量内积 × 归一化”的结构。

定义： 常见形式$p_\eta(z) = h(z)\exp[\eta^\top T(z) - A(\eta)]$，A负责让积分为1。

例子： 高斯中T(z)包含z和z²；取对数后，复杂的指数变成关于这些统计量的线性组合。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** “对统计量线性”不表示“对原始数据线性”。T(z)=z²本身就是非线性函数。

编码器与解码器 • encoder / decoder

直觉： 编码把观测变成特征；解码或生成把特征变回观测。

定义： 本文编码器τ把激活g(x)压缩成学习特征$\hat{z} = \tau(g(x))$。附录有时将复合函数写成$\hat{f}(x)$。解码器仅在自编码实现/基线中用于重构。

例子： 图片输入编码器得到颜色、形状等向量；生成器把一组潜变量变成图像。

在论文中的用途： 不能把本文τ、g与上一篇的f^{-1}直接当作同一个已识别函数。

> **别混淆：** 输出n个概念值不意味着可以用n<d_z个连续坐标无损重建整个观测流形。

学习与算法

损失函数 • loss function

直觉： 把模型做得不好这件事转成一个可计算、希望变小的数。

定义： 学习算法通常最小化样本损失加正则。损失的定义决定了模型被鼓励完成什么任务。

例子： 预测0/1标签时，交叉熵会给“对错误答案非常自信”的预测很大惩罚。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 损失低不自动等于因果正确。模型可能利用捷径或落在不满足定理约束的参数空间。

对比学习 • contrastive learning

直觉： 通过比较或区分不同来源的样本，学习能解释差别的特征。

定义： 本文的具体做法是二分类：条件环境样本标签为1，基准环境样本标签为0，共享编码器为多个环境提供特征。

例子： 若红色物体是条件环境、整个图片库是基准环境，分类器需要捕捉两者的分布差异。

在论文中的用途： 本篇在不同行为组中寻找近似只差一个坐标的样本；它不是上一篇基准环境对条件环境的二分类密度比算法。

> **别混淆：** “对比学习”是宽泛名称。不要把本文的环境分类损失与所有InfoNCE或配对学习算法视作同一公式。

Sigmoid与logit • sigmoid / logit

直觉： Sigmoid把任意实数分数压到0与1之间；logit把概率变回相应的实数分数。

定义： $\mathrm{sigmoid}(r) = 1/(1+e^{-r})$；$\mathrm{logit}(p) = \log[p/(1-p)]$，要求0<p<1。

例子： r=0对应p=1/2；p=0.8对应logit=log4。r=2不是“概率为2”。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** “log概率”与“logit概率”不同。后者包含p与1−p的比值。

交叉熵 • cross entropy

直觉： 检查模型给真实答案分配了多少概率；真实答案概率越小，惩罚越大。

定义： 二分类单样本损失为$-y\log p-(1-y)\log(1-p)$。用logit r写成$\log(1+e^r)-yr$。

例子： 真实y=1时，p=0.8的损失为−log0.8≈0.223；p=0.2时约为1.609。

在论文中的用途： 公式(3)预测的是粗粒度行为标签c。原文y也表示输出文本，公式中的y需解释为类别索引，而不是整段文本。

> **别混淆：** 交叉熵与准确率不同。两个模型分类对错一样多，置信度不同仍可有不同交叉熵。

正则化与稀疏 • regularization / sparsity

直觉： 在拟合数据之外，额外偏好某类结构，例如更少的非零参数。

定义： 常见目标是$L(\theta)+\lambda R(\theta)$。$\ell_1$惩罚为$\sum_i|\theta_i|$，常用于鼓励稀疏。

例子： 两个分类器拟合相近时，可以更偏好只使用少数概念坐标的那个。

在论文中的用途： 本篇主要约束“样本间变化稀疏”，而SAE约束“单一样本的激活稀疏”。两种稀疏性不是一回事。

> **别混淆：** 加了稀疏惩罚不代表已证明找到了真实原子；正则化也不能替代可识别性条件。

拒绝采样 • rejection sampling

直觉： 先从容易抽样的分布提议，再按一个概率保留样本，从而得到想要的分布。

定义： 目标$p_C\propto p^0w$，若$0\le w(z)\le M$，则从p^0抽z，以$w(z)/M$接受。

例子： 三种颜色先各抽到1/3概率，再以不同概率保留，就能改变保留样本中的颜色比例。

在论文中的用途： 这是上一篇的生成采样方法，不是本篇的核心算法。本篇每个锚点采5个候选，是近似内层最小化，不是拒绝采样。

> **别混淆：** 上界太小会破坏正确性；上界太大或目标区域太稀有，会使算法很慢。

优化收敛 • optimization / stationary point / backpropagation

直觉： 优化是在某个已选定的目标函数上找小值；收敛只说明算法在某种意义上稳定或接近目标。

定义： 可微无约束问题的驻点满足$\nabla L = 0$，但可能是局部最小、极大或鞍点。反向传播是用链式法则高效计算网络参数梯度。

例子： $L(\theta) = \theta^2$在0处为最小；$L(\theta) = -\theta^2$在0处也梯度为0，却是极大。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 稳定训练、全局最优、统计一致和语义正确是不同层次的结论。

因果与LLM

因果干预 • causal intervention

直觉： 不是挑选已经发生的结果，而是主动替换系统里某个变量的生成机制。

定义： 结构方程模型写$Z_i = f_i(\mathrm{Pa}_i, \epsilon_i)$；$\mathrm{do}(Z_i = b)$把这一条方程替换成常数b，其他方程保持。

例子： 观察“开空调的房间更热”可能因天气炎热导致开空调；主动打开空调的效果不能只靠这种观察相关性判断。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** “干预”一词在不同领域含义有层级差别。必须说清改变了什么、保留了什么机制。

因果图与DAG • causal graph / DAG

直觉： 用箭头表示变量间的直接因果关系；DAG要求沿箭头走不会绕回原点。

定义： DAG是有向无环图，邻接矩阵记录哪些有向边存在。单有观察分布通常还会有因果方向的等价类。

例子： U→V→W无环；U→V→U含有有向环。你以前的连续因果发现主要在搜索这类图结构。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 把特征画成流程图，不会自动使流程图变成经过识别的因果图。

概念编辑与steering • concept editing / steering

直觉： 在模型运行时给内部表示施加改动，希望某个概念或行为向指定方向变化。

定义： 在固定激活空间中，若概念测量是A，希望目标改变d，则要求$A\eta = d$；最小欧氏范数解在可解条件下为$\eta = A^{+}d$。

例子： 激活差(1,1)和(1,−1)平均为(1,0)，第一坐标目标保留，第二坐标副作用抵消。

在论文中的用途： 本文主要发现和解释概念，没有证明每个发现方向都已通过真实模型编辑验证。不要把潜空间图自动当成干预成功证据。

> **别混淆：** 能改变输出不等于精确恢复了真实概念，也不保证所有非目标能力或语境保持不变。

KL散度 • KL divergence

直觉： 衡量用一个概率分布来代替另一个分布时的信息差异；不是普通几何距离。

定义： 离散时$D_{\mathrm{KL}}(P\|Q) = \sum_x P(x)\log[P(x)/Q(x)]$，通常不对称；在适当绝对连续条件下非负。

例子： 若编辑后的模型给下一token分配的概率与原模型大幅不同，KL通常会变大。

在论文中的用途： VAE预训练使用KL项。本篇主要实验表的I是DCI信息性，不是KL，也不是互信息。

> **别混淆：** KL小不保证回答真实或安全；KL大也不能单独证明任务能力变差。P与Q的方向必须说明。

激活与注意力头 • activation / attention head

直觉： 激活是网络处理某个具体输入时在中间算出的数值；注意力头是Transformer中产生特定信息汇聚输出的模块。

定义： 一层或一个head的激活通常是向量。模型权重在推理时通常固定，激活则随问题、token位置和上下文变化。

例子： 同一模型回答两个不同问题，其参数可以不变，但末token的head激活会不同。

在论文中的用途： 这是通用基础。请结合本篇的行为标签c、中介概念z、激活g(x)与编码器τ来阅读；它不是额外添加的论文假设。

> **别混淆：** 权重不是激活。探针能读出信息，也不等于沿其方向编辑一定获得最好的因果控制。

CDC专用概念

Softmax • softmax

直觉： 把多个实数分数变成总和为1的类别概率。

定义： $p(c \mid z) = \exp(w_c^\top z) / \sum_j \exp(w_j^\top z)$。所有类别分数加上同一个数，概率不变。

例子： 分数(0,0)给概率(1/2,1/2)；分数(0,\log3)给(1/4,3/4)。

在论文中的用途： 假设1使用logit线性softmax，定理1从相同类别概率出发。

> **别混淆：** 分母通常随输入z变化；类别数多不等于所有概念方向都能由概率识别。

类别参考对数几率 • reference log odds

直觉： 用一个参考类别作分母，消掉softmax的公共归一化项。

定义： $\log[p(c \mid z)/p(0 \mid z)] = (w_c - w_0)^\top z$。若分类器有截距，还要保留截距差。

例子： 不管分母的log-sum-exp有多复杂，同一输入、两个类别相除时它会精确抵消。

在论文中的用途： 这是补全定理1推导的关键，比把归一化差误当成输入无关常数更可靠。

> **别混淆：** log p(c)与log[p(c)/p(0)]不是同一个数。

换位干预 • interchange intervention

直觉： 保留一个样本的大多数概念，只把指定坐标换成另一个样本的对应值。

定义： 对集合S，令$z'_r = z_{l,r}$若r属于S，否则$z'_r = z_{k,r}$，再在高层模型M中计算行为。

例子： 把候选人的职业替换为另一人的职业，但保留原人的性别与其他因素。

在论文中的用途： 定义1用它构造因果区分概念的必要与充分条件。

> **别混淆：** 在抽象变量中能写出干预，不保证自然文本中存在完全对应的输入。

必要条件 • necessary condition

直觉： 想成功就不能缺少它，但具备它不一定成功。

定义： “A是B的必要条件”是$B \Rightarrow A$。本文要求若干必要坐标没被替换，就不能从指定组到达目标组。

例子： 持票可能是进场的必要条件，但持票后仍可能因场馆关闭而无法进场。

在论文中的用途： 公式(1)含对所有组间样本的量词，不是只观察一个干预失败就足够。

> **别混淆：** 必要不是充分，也不是“这个因素与标签相关”。

充分条件 • sufficient condition

直觉： 在规定的情形下，做这件事就足以得到结果。

定义： “A是B的充分条件”是$A \Rightarrow B$。本文公式(2)只要求存在某一对样本，交换S后到达目标组。

例子： 某一对职业不同的样本，只替换职业就改变行为；不表示任何职业替换都会改变行为。

在论文中的用途： 公式(2)是存在量词，与公式(1)的全称量词强度不同。

> **别混淆：** 一个成功案例不等于所有情形都成功。

因果区分概念 • causal differentiating concept

直觉： 对指定的两个行为组，为了把行为变过去，不能遗漏且在某些情形足够的那组概念坐标。

定义： 按定义2，一个坐标集合S同时满足必要性和存在性的充分条件。若S只有一个元素，就称1-sparse CDC。

例子： 收入预测中的高职业收入组与低职业收入组，职业可能是区分坐标；不同组对的区分坐标可以不同。

在论文中的用途： 假设2要求每个真实概念至少在某一组对中作为单坐标CDC，而不是所有组对都只差一个坐标。

> **别混淆：** CDC不是所有对输出有相关性的因素，也不自动等于一个物理因果变量。

单稀疏变化 • one-sparse shift

直觉： 改变向量时只有一个坐标发生非零变化。

定义： $\delta = ae_r$，a非零；e_r是第r个标准基向量。这里的稀疏对象是变化δ，不是整条表征z。

例子： z=(2,3)变成(2,7)，差为(0,4)，是单稀疏；z本身两个分量都非零并不妨碍。

在论文中的用途： 公式(4)尝试学习不同组间的共享单坐标平移。

> **别混淆：** 所有变化都沿同一个轴仍可能漏掉其他概念，所以还需要覆盖约束。

扰动覆盖约束 • shift span coverage

直觉： 找到的单坐标变化不能只反复解释同一条轴，必须覆盖全部目标方向。

定义： 正确写法为$\dim \operatorname{span}\{\hat{\delta}_{kl}\} = d$，或把扰动叠成矩阵D后要求rank(D)=d。

例子： (1,0)和(2,0)只覆盖一维；(1,0)和(0,1)才覆盖二维。

在论文中的用途： 论文在公式(4)后的文字中提出这个约束，但没有给出唯一的实际求解器。

> **别混淆：** 轴标签覆盖全部坐标还不够：对应扰动幅度也必须非零。

瓶颈表征 • bottleneck representation

直觉： 把高维激活压成较少的特征，迫使模型选择保留的信息。

定义： 从$g(x) \in \mathbb{R}^n$经τ得到$\hat{z} \in \mathbb{R}^d$，通常d远小于n。

例子： 768维文本激活压成2维概念后，可以画成平面，但画得成平面不代表语义已经正确。

在论文中的用途： 预测头使瓶颈保留行为相关信息；稀疏变化约束再试图固定坐标方向。

> **别混淆：** 低维、能预测与可解释是不同性质。

内层候选最小化 • inner candidate minimization

直觉： 先在若干候选中找最符合某个轴平移的配对，再更新表示。

定义： 固定锚点i与δ时，计算$\min_{j \in \mathcal{J}} \|\hat{z}_j - \hat{z}_i - \delta\|^2$。附录B采5个候选近似这个搜索。

例子： 三个残差平方是4、1、9时，内层返回1，而不是均值14/3。

在论文中的用途： 候选数影响找到近配对的机会，因此“同一损失”在不同候选预算下不可直接比较。

> **别混淆：** min和期望通常不能互换，采5个候选不等于全体样本的精确最小值。

反事实可实现性 • counterfactual realizability

直觉： 高层模型中能构造一个状态，还需要确认数据输入空间确实能产生这个状态。

定义： 观察集合若对相关干预封闭，干预后的z能对应到某个合法输入x；否则不能直接把反事实状态当作已有样本。

例子： 观测只有(0,0)和(1,2)，替换第一坐标产生(1,0)，不代表数据中就有(1,0)。

在论文中的用途： 推论1从“干预成功”跳到“存在仅差一个坐标的观测配对”时，需要核查这条桥梁。

> **别混淆：** 这类反例用于检查推论所需条件，不自动否定所有带额外支撑条件的定理。

变分自编码器 • variational autoencoder

直觉： 把输入编码成一个分布，抽取潜表示再重构输入，同时约束这个潜分布。

定义： 常见目标为重构误差加$\beta D_{KL}(q_\phi(u \mid x) \| p(u))$。采样常写成$u = \mu + \sigma \odot \epsilon$。

例子： 均值编码告诉模型输入的位置，噪声和KL项限制记忆方式；它不自动得到真实概念坐标。

在论文中的用途： 论文用VAE训练合成数据的g(x)，再在冻结特征上学习解释映射。

> **别混淆：** VAE是低层特征来源；不是作者已经知道真实z的证据。

DCI指标 • disentanglement completeness informativeness

直觉： 分别问每个特征是否专一、每个真实因素是否集中、整体是否保留足够信息。

定义： 用一个可预测真实因子的评价器，得到特征重要性矩阵R，再按行列熵计算D和C；I由独立测试预测性能定义。

例子： 一个旋转后的完整表示可以保留全部信息，但每个轴混合多个因素，因此I高而D、C低。

在论文中的用途： 本实验公布训练评价器、熵公式及测试R^2/准确率定义，不能把不同I定义混在一起直接比较。

> **别混淆：** 需要真实因素标签才能直接计算这些监督指标；真实拒答案例通常没有这种标签。

解缠度 • disentanglement

直觉： 每个学习特征最好只负责一个真实因素。

定义： 在重要性矩阵R中，对每个特征的行跨真实因素归一化，计算1减归一化熵，再按该行总重要性加权。

例子： 一行重要性为(1,0)时完全专一；一行为(0.5,0.5)时同样依赖两个因素。

在论文中的用途： 用于检查学到的轴是否混合职业和性别等因素。

> **别混淆：** 漂亮的二维簇图或高分类准确率不是这个指标的替代。

完整度 • completeness

直觉： 一个真实因素最好只由一个学习特征承担，而不是散布在多个冗余特征中。

定义： 对R的每个真实因素列归一化，计算1减跨特征的熵，再按列的重要性加权。

例子： 两个学习特征都复制同一个真实因素时，各自可以专一，但这个因素不集中于单个特征，C会下降。

在论文中的用途： 用于研究过多的学习维度是否把同一因素分裂到多轴。

> **别混淆：** 完整度不是“所有变量都已恢复”的形式化证明。

信息性 • informativeness

直觉： 把整组学习特征一起交给评价器，能否预测真实因素。

定义： 原论文将I解释为整体保留因素信息；具体数值取决于评价器和预测分数。本实验连续因子用测试R^2，离散因子用测试准确率。

例子： 把两个坐标作可逆旋转没有丢信息，所以足够灵活的评价器仍可能预测得很好。

在论文中的用途： I与D/C一起看，区分“信息保留”与“坐标对齐”。

> **别混淆：** 测试R^2可能为负；它不是概率，也不是互信息，更不能因想保持0到1就悄悄截断。

平均相关系数 • mean correlation coefficient

直觉： 把学习轴与真实因素作最佳一一匹配，再看线性相关有多强。

定义： 等维时$\mathrm{MCC} = \max_\pi d^{-1} \sum_i |\operatorname{Corr}(\hat{z}_i, z_{\pi(i)})|$。绝对值允许符号翻转。

例子： 二维独立同方差因素旋转45度后仍完整保留信息，但MCC只有约0.707。

在论文中的用途： 本实现用线性分配精确求解最佳匹配，并公开相关矩阵。

> **别混淆：** 它主要检查线性逐轴关系；与DCI的树模型评价器不完全同义。

测试集泄漏 • test leakage

直觉： 用本该只在最后评估的数据来决定训练或选择，从而让结果过于乐观。

定义： 标准化参数、拟合评价器和选模型应使用训练/验证数据；测试数据只用于最终报告。

例子： 尝试100个λ后只挑测试MCC最高的一次，再称其为无偏测试结果，就泄漏了。

在论文中的用途： 本实验预先固定λ、结构和种子，按验证目标选择轮次；作者用验证真实因素DCI调参，是需要单独说明的监督信息。

> **别混淆：** 指标定义中的最优置换匹配是评价对齐约定，不等于可以据测试分数反复调模型。

随机种子与不确定性 • random seed and uncertainty

直觉： 区分“同一模型在不同测试子集上波动”与“重新训练不同模型的波动”。

定义： n次独立运行的样本标准差为s；正态模型下均值置信区间可写成$\bar{x} \pm t_{n-1,0.975} s/\sqrt{n}$。

例子： 一个已训练模型把测试集切5份，不等于用5个种子重新训练。

在论文中的用途： 本实验报告3个预先指定种子的所有结果和跨运行样本SD；小n的置信区间和t检验需要谨慎解释。

> **别混淆：** ±1 SD不是95%置信区间；固定种子也不保证跨硬件/版本逐位相同。

显著性检验 • significance test

直觉： 在零假设及其抽样模型成立时，衡量当前差异有多不寻常，不是“理论成立概率”。

定义： 同一数据/种子下的方法比较宜考虑配对结构；重复多个检验需要说明校正与检验家族。

例子： 若只有作者四舍五入的均值，没有原始预测或重复运行数据，就不能重新算出其真实p值。

在论文中的用途： 原文把同一测试集分5份后作独立t检验；本材料区分这种波动与训练重复，并公布可重算的新实验。

> **别混淆：** p<0.05不说明效果大、因果关系正确或所有其他设置也会成功。

冻结编码器 • frozen encoder

直觉： 提取特征的语言模型权重保持不变，只训练后面的小网络。

定义： 推理时设model.eval并停止梯度，只保存g(x)；后续优化τ和预测/重构头。

例子： 一次抽取2400条文本的768维激活后，可以在CPU上重复训练多个小瓶颈模型。

在论文中的用途： 这是本机半合成实验的明确缩小方案，与可能微调完整LM的原文实验不能直接当成完全一致。

> **别混淆：** 冻结不意味着激活对所有输入相同；激活仍然随文本变化。