先修｜从零补课：读懂这篇论文需要的数学

> **这是教学补充，不是论文新增结论。** 本章不用你预先记得线性代数、概率或优化。先抓住“文本→激活→概念→行为”这条主线，遇到虚线术语可以点开词典。

1. 先分清五个东西

符号	是什么	例子
x	输入文本	一段职业简介及提问
$g(x)$	模型内部可提取的激活	768维向量
z	我们希望发现的真实中介概念	性别编码、职业收入等级
$\hat{z} = \tau(g(x))$	算法学出的低维特征	两个实数，但起初不知道各自含义
c	想解释的粗粒度行为类别	高收入判断、低收入判断等

“概念没标签”不等于“完全没有任何标签”：训练仍知道每条输入属于哪个行为组c。



教学图：训练可见文本、激活和行为；真实概念仅在可控实验中用来评价。箭头表示建模流程，不宣称已恢复现实因果图。

2. 向量只是有顺序的一串数

$z = (2, 3)$是一个二维向量。第一个分量可能表示职业等级，第二个表示另一个属性。坐标的单位和顺序是约定，不是自然定律。

从$(2, 3)$变成$(2, 7)$，变化量是$(0, 4)$。只有一处非零叫**单稀疏变化**。它不要求原向量本身稀疏。

标准基向量$e_1 = (1,0)$、$e_2 = (0,1)$是两条坐标轴的单位箭头，所以$(0,4) = 4e_2$。

3. 矩阵是在做混合

$$A = \begin{pmatrix} 2 & 1 \\ -1 & 3 \end{pmatrix}, \quad Az = \begin{pmatrix} 2z_1 + z_2 \\ -z_1 + 3z_2 \end{pmatrix}.$$

代入$z = (1,2)$，得到$Az = (4,5)$。两个新坐标都混合了旧概念：能保留信息，却不再逐轴对应语义。

矩阵乘e_1会抽出第一列：$Ae_1 = (2,-1)$。这正是公式(5)为什么能把“单坐标变化”转换成“矩阵某列只有一个非零数”。

4. 满秩、可逆与覆盖

秩表示独立方向有多少。$(1,0)$与$(2,0)$虽然有两条箭头，却只张成一条线；$(1,0)$与$(0,1)$才能覆盖整个平面。

$$\operatorname{rank}\begin{pmatrix} 1 & 0 \\ 2 & 0 \end{pmatrix} = 1, \qquad \operatorname{rank}\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = 2.$$

矩阵“行很多”不保证满秩。四个行为类别的权重都平行，仍然只提供一个方向的信息。这是核查定理1时最重要的基础。

5. 仿射、旋转、尺度与置换

仿射变换是$\hat{z} = Az + b$，包括混合A和统一平移b。

- 置换：把第一、第二坐标对调。
- 尺度：把某个坐标乘2或乘-1。
- 旋转：两个坐标互相混合，但不一定丢信息。

“识别到置换和尺度”表示算法找到了正确的轴，但不能凭数据确定轴的顺序、方向和单位。若未中心化，平移也不能由差分损失识别。

6. 概率与条件概率

$p(c=1 \mid z)$读作“给定概念z时，行为为1的概率”。固定z后，各行为类别概率之和是1。

同一组概念若对应随机行为，就不能再假装c一定是z的确定函数。论文在高层模型$\mathcal{M}$与条件概率间切换，严格阅读时必须注明采用哪一种解释。

7. 条件独立不是所有变量相互独立

$c \perp x \mid z$表示：知道z后，x不再提供额外的行为预测信息。

例如如果模拟标签只由性别与收入等级生成，知道这两个因素后，简介里的标点不再影响模拟标签。它没有说性别与职业彼此独立，也没有证明现实收入只受这两者影响。

8. 指数、对数和Softmax

指数$\exp(t)=e^t$把实数变成正数。对数log是其反操作：$\log(e^t)=t$。

$$p(c \mid z)=\frac{\exp(w_c^\top z)}{\sum_j \exp(w_j^\top z)}.$$

两类分数$(0, \log 3)$对应概率$(1/4, 3/4)$。同时给所有分数加5，概率不变，因为分子分母都多乘e^5。

不要把分母看作输入无关常数：输入变了，所有分数通常都变。

9. 对数几率为什么能消去分母

用类别0作参考：

$$\log \frac{p(c \mid z)}{p(0 \mid z)}=(w_c-w_0)^\top z.$$

这是两个概率相除后，**同一个输入的同一个分母**精确抵消。它不同于对单个$\log p(c \mid z)$随意丢掉归一化项。

10. 交叉熵是什么

真实标签为c时，模型损失是$-\log \hat{p}_c$。给正确类别概率越高，损失越低：

$$-\log 0.9 \approx 0.10536, \qquad -\log 0.1 \approx 2.30259.$$

如果真实类别比例是$(0.25, 0.75)$，预测同样比例时总体平均损失约0.562335；始终预测$(0.5, 0.5)$时是$\log 2 \approx 0.693147$。

总体交叉熵的最低点是“正确预测概率”，不保证神经网络在有限数据和有限轮次就到达该点。

11. 范数与平方误差

向量$v = (3, 4)$的欧氏长度是$\|v\| = 5$，平方长度$\|v\|^2 = 25$。两者不是一个损失。

本篇正式PDF公式(4)中的2是**上标平方**。我们计算的是平方残差；不能把原文偷偷改写成未平方的欧氏长度，然后用同一数值比较。

12. 最小值、期望与求和

- $\min$：在候选中找最小值。
- $\mathbb{E}$：按概率加权平均。
- $\sum$：把多项相加。

候选损失是4、1、9，最小值为1，平均为$14/3$。一般$\mathbb{E}[\min L]$不等于$\min \mathbb{E}[L]$；论文的简写与附录采样实现需要区别说明。

候选越多，取得小最小值的机会通常越大。所以比较方法时必须保持候选预算一致。

13. 换位干预与自然配对

已有$z_A = (0, 0)$、$z_B = (1, 2)$。只替换第一坐标，可构造$(1, 0)$。

这是一个**反事实状态**。观察数据只有前两点时，并没有证据说自然样本中存在$(1, 0)$。从高层干预转成可供搜索的真实文本，需要额外的可实现性或支撑条件。

14. 必要、充分与量词

“必要”是没有它不行；“充分”是有它就够。两者合起来也必须看“对所有”还是“存在一些”。

本文必要条件是强的全称条件，充分条件仅要求存在某对样本干预成功。不能把“存在一例”读成“任意样本都成功”。

15. 导数、梯度与训练

若$L(a)=(a-3)^2$，导数$L'(a)=2(a-3)$。在$a=1$时导数为-4，取步长0.1更新：$a \leftarrow 1-0.1(-4)=1.4$，更接近3。

神经网络把a换成很多参数，梯度是每个参数的导数。自动求导可以算梯度；有限差分可以检查实现，但不能证明优化总能找到全局最优。

16. VAE与瓶颈

VAE学习压缩与重构，并加一个分布约束；本文先借它得到合成数据的低层特征$g(x)$。之后再训练τ得到用于解释的瓶颈。

仅靠重构或预测，许多旋转后的瓶颈都同样好。对比约束的目的，就是尝试从这些等价坐标中选出概念轴。

17. D、C、I和MCC分别问什么

指标	问题	不能说明什么
D	一个学习轴是否只负责一个真实因素?	不能独立证明信息没丢
C	一个真实因素是否集中在一个学习轴?	不等于覆盖全部现实因素
I	全部学习特征能否预测真实因素?	高I不等于坐标已经对齐
MCC	最佳一一配对后线性相关多强?	不能检测所有非线性等价关系

矩阵$R=\begin{pmatrix}0.8 & 0.2\\ 0.2 & 0.8\end{pmatrix}$给出$D=C=1-H_2(0.8)\approx 0.278072$。不要把0.8直接当作解缠分数。

18. 数据划分与公平比较

训练集用于更新参数，验证集用于选择轮次，测试集只在最后评估。标准化均值和标准差也必须只用训练集估计。

这次合成实验每个数据集20000条，按70:15:15得到14000、3000、3000条。所有方法使用同一数据、划分和轮次，不按测试指标挑模型。

19. 均值、标准差和显著性

三次结果是$0.5, 0.6, 0.7$，均值为0.6，样本标准差为0.1。写0.6 ± 0.1时必须说明这是SD，不是95%置信区间。

重新训练3次与把同一模型的测试集切成3份，描述的波动不一样。少量重复的统计检验很不稳定，本材料保留逐种子结果，不用一颗“显著星号”替代它们。

20. 五个自测

1. 两个学习坐标混合了职业和性别，但可以无误预测行为，能否认定解缠?
2. 四个类别的权重都是$(1, 1)$的倍数，是否一定能识别二维概念?
3. 反事实$(1, 0)$可生成，是否说明真实数据已有这个输入?
4. 表征整体乘0.1，预测头除以0.1，平方对比损失如何变化?
5. DCI-I在本地连续实验采用测试R^2，能与另一个未披露定义的1.0直接作严格数值比较吗?

▼ 查看答案

1. 不能，行为信息充分不等于逐轴语义对齐。
2. 不一定，权重差最多秩1。
3. 不能，需要可实现性/闭包条件。
4. 预测logits不变；扰动同样缩放后，平方残差变为原来的0.01。
5. 不能，先统一评价器、数据与指标定义。

继续：整篇路线图。所有手算数值与基础例子由验证脚本重新计算；有限检验不替代一般证明。